



**YILDIZ TEKNİK ÜNİVERSİTESİ
KİMYA-METALÜRJİ FAKÜLTESİ
MATEMATİK MÜHENDİSLİĞİ BÖLÜMÜ**

Matematik Mühendisliği Bitirme Projesi

**Makine Öğrenmesi, Zaman Serisi ve Derin Öğrenme
Yöntemleriyle
Elektrik Enerjisi Fiyat ve Tüketim Tahmini**

Tez Yöneticisi: Doç. Dr. Mert BAL

21052045 Kerem REYHANI

İstanbul, 2026

İÇİNDEKİLER

KISALTMA LİSTESİ.....	iv
TABLO LİSTESİ.....	v
ŞEKİL LİSTESİ.....	vi
ÖNSÖZ.....	vii
ÖZET.....	viii
ABSTRACT.....	ix
1. GİRİŞ.....	1
1.1. Konunun Önemi.....	1
1.2. Çalışmanın Amacı.....	2
1.3. Temel Kavramlar.....	2
1.3.1. Alan ve Veri Kavramları.....	2
1.3.2. Modelleme ve Metodoloji Kavramları.....	3
1.3.3. Model Değerlendirme Metrikleri.....	3
2. LİTERATÜR TARAMASI.....	4
2.1. Klasik İstatistiksel ve Zaman Serisi Yöntemleri.....	4
2.2. Makine Öğrenmesi Yaklaşımları.....	4
2.3. Derin Öğrenme Mimarileri.....	5
2.4. Hibrit Tahmin Çerçeveleri.....	5
2.5. Türkiye'ye Yönelik Çalışmalar ve Literatür Boşluğu.....	6
3. VERİ SETİ, ÖN İŞLEME VE KEŞİFSEL ANALİZ.....	7
3.1. Veri Kaynakları.....	7
3.2. Ön İşleme Adımları.....	8
3.3. Keşifsel Analiz Bulguları.....	10
3.3.1. Saatlik Ortalama Tüketim ve Fiyat Profili.....	10
3.3.2. Tüketim Dağılımı ve İki Tepeli Yapı.....	10
3.3.3. Sıcaklık ve Elektrik Tüketimi İlişkisi.....	11
3.3.4. Korelasyon Analizi ve Çoklu Bağlantı.....	12
3.3.5. Durağanlık Testleri.....	13
3.3.6. Otokorelasyon ve Çapraz Korelasyon Analizi.....	13
3.3.7. Sıcaklık Etkisi — Optimal Lag Tespiti (Çapraz Korelasyon).....	14
3.3.8. Trend ve Yapısal Kırılma.....	15
4. YÖNTEM.....	17
4.1. Araştırma Tasarımı ve Veri Bölme Stratejisi.....	17
4.2. Özellik Mühendisliği.....	17
4.2.1. Gecikmeli Değişkenler.....	18
4.2.2. Hareketli İstatistikler.....	18
4.2.3. Döngüsel Zaman Kodlaması.....	18
4.2.4. Hava Durumu Türevleri.....	18
4.2.5. Veri Sızıntısı Kontrolü.....	18
4.3. Değerlendirme Metrikleri.....	19
4.4. Modelleme Yaklaşımı ve Model Ailelerine Genel Bakış.....	19
4.5. Makine Öğrenmesi Modelleri.....	20

4.5.1. Doğrusal Regresyon ve Ridge Regresyon	20
4.5.2. ElasticNet.....	21
4.6. Karar Ağacı Tabanlı Modeller.....	21
4.6.1. Karar Ağacı.....	21
4.6.2. Random Forest.....	21
4.7. Gradient Boosting Tabanlı Modeller	22
4.7.1. Gradient Boosting	22
4.7.2. XGBoost	22
4.7.3. LightGBM.....	22
4.8. Klasik Zaman Serisi Modelleri.....	22
4.8.1. SARIMAX	22
4.8.2. VARMAX.....	23
4.9. Derin Öğrenme Modelleri	23
4.9.1. CNN-LSTM	23
4.9.2. Temporal Fusion Transformer (TFT)	23
4.10. Hibrit Meta-Öğrenme Modeli.....	24
5. BULGULAR	25
5.1. Makine Öğrenmesi Modelleri: Saatlik Tüketim	25
5.2. Makine Öğrenmesi Modelleri: Saatlik Fiyat	26
5.3. Klasik Zaman Serisi Modelleri: SARIMAX ve VARMAX.....	28
5.4. Derin Öğrenme Modelleri: CNN-LSTM ve TFT	29
5.5. Hibrit Meta-Öğrenme Modeli.....	30
6. SONUÇ	32
7. ÇALIŞMANIN SINIRLILIKLARI.....	33
8. GELECEĞE YÖNELİK ÇALIŞMALAR	34
KAYNAKÇA	35
ÖZGEÇMİŞ	36

KISALTMA LİSTESİ

Kısaltma	Açıklama
ACF	Otokorelasyon fonksiyonu
ADF	Augmented Dickey-Fuller durağanlık testi
API	Uygulama programlama arayüzü
CDD	Cooling Degree Day / soğutma derece günü
CNN	Convolutional Neural Network / evrimsel sinir ağı
EPİAŞ	Enerji Piyasaları İşletme A.Ş.
GARCH	Generalized Autoregressive Conditional Heteroskedasticity
GRU	Gated Recurrent Unit
HDD	Heating Degree Day / ısıtma derece günü
KPSS	Kwiatkowski-Phillips-Schmidt-Shin durağanlık testi
LightGBM	Light Gradient Boosting Machine
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error / ortalama mutlak hata
MAPE	Mean Absolute Percentage Error / ortalama mutlak yüzde hata
MCP	Market Clearing Price / piyasa takas fiyatı
MWh	Megawat-saat
NRMSE	Normalized Root Mean Square Error
PACF	Kısmi otokorelasyon fonksiyonu
PTF	Piyasa Takas Fiyatı
RMSE	Root Mean Square Error / hata kareleri ortalamasının karekökü
SARIMA	Seasonal Autoregressive Integrated Moving Average
SARIMAX	Seasonal Autoregressive Integrated Moving Average with Exogenous Variables
SHAP	SHapley Additive exPlanations
sMAPE	Symmetric Mean Absolute Percentage Error
STLF	Short-Term Load Forecasting / kısa vadeli yük tahmini
TEİAŞ	Türkiye Elektrik İletim A.Ş.
TFT	Temporal Fusion Transformer
TL	Türk lirası
TÜİK	Türkiye İstatistik Kurumu
VARMAX	Vector Autoregressive Moving-Average with Exogenous Variables
XGBoost	Extreme Gradient Boosting

TABLO LİSTESİ

Tablo 3.1: Veri Setindeki Değişkenler	8
Tablo 3.2: Durağanlık Testleri	13
Tablo 3.3: Yıllık İstatistiksel Özet	15
Tablo 4.1: Zaman temelli train-validation-test bölme stratejisi	17
Tablo 4.2: Kullanılan model ailelerine genel bakış.....	19
Tablo 5.1: Makine öğrenmesi saatlik tüketim modelleri karşılaştırması	25
Tablo 5.2: Makine öğrenmesi saatlik fiyat modelleri karşılaştırması	26
Tablo 5.3: Günlük zaman serisi model karşılaştırması	28
Tablo 5.4: Derin öğrenme saatlik model karşılaştırması.....	29
Tablo 5.5: Nihai günlük hibrit model karşılaştırması (test dönemi 2025)	30

ŞEKİL LİSTESİ

Şekil 3.1: Saatlik Elektrik Tüketimi	7
Şekil 3.2: Veri Seti Örneği	9
Şekil 3.3: Saatlik Ortalama Tüketim ve Fiyat Profili	10
Şekil 3.4: Tüketim Dağılımı	10
Şekil 3.5: Fiyat Dağılımı	11
Şekil 3.6: Sıcaklık ve Elektrik Tüketimi İlişkisi	11
Şekil 3.7: Korelasyon Matrisi	12
Şekil 3.8: ACF – PACF Testleri	14
Şekil 3.9: Sıcaklık Etkisi Grafikleri	14
Şekil 3.10: Trend ve Yapısal Kırılma Grafikleri	15
Şekil 5.1: Tüketim SHAP Analizi	26
Şekil 5.2: Fiyat SHAP Analizi	28
Şekil 5.3: Zaman Serileri Model Sonuçları	29

ÖNSÖZ

Bu çalışma, Türkiye elektrik piyasasında kısa vadeli elektrik tüketimi ve piyasa takas fiyatı tahmini problemini makine öğrenmesi, zaman serisi ve derin öğrenme yöntemleri çerçevesinde ele almak amacıyla hazırlanmıştır. Elektrik enerjisinin üretim ve tüketim dengesinin anlık olarak korunması gerekliliği, doğru tahmin modellerinin enerji planlaması, talep yönetimi ve piyasa analizi açısından önemini artırmaktadır. Bu doğrultuda çalışmada, EPIAŞ Şeffaflık Platformu’ndan elde edilen elektrik verileri ile farklı iklim bölgelerini temsil eden şehirlerden alınan meteorolojik veriler bir araya getirilmiş; çeşitli modelleme yaklaşımları karşılaştırmalı olarak değerlendirilmiştir.

Bitirme projesi sürecinde veri toplama, ön işleme, keşifsel analiz, özellik mühendisliği, modelleme ve performans değerlendirme aşamaları birlikte ele alınmıştır. Bu süreç, yalnızca teknik modelleme becerilerimin gelişmesine değil, aynı zamanda gerçek dünya verileriyle çalışmanın getirdiği metodolojik zorlukları daha iyi kavramama da katkı sağlamıştır.

Çalışmam boyunca bilgi ve yönlendirmeleriyle bana destek olan tez yöneticim Sayın Mert BAL’a teşekkürlerimi sunarım. Ayrıca eğitim hayatım boyunca bana destek olan aileme, arkadaşlarıma ve akademik gelişimime katkıda bulunan tüm hocalarıma içtenlikle teşekkür ederim.

Bu çalışmanın, elektrik tüketimi ve fiyat tahmini alanında yapılacak ileriki araştırmalara katkı sağlamasını temenni ederim.

Kerem Reyhani
İstanbul, 2026

ÖZET

Bu çalışmada meteorolojik değişkenlerin katkısıyla Türkiye'nin kısa vadeli elektrik tüketimi ve elektrik piyasa takas fiyatı (PTF) tahmini ele alınmıştır. Saatlik elektrik üretim, tüketim ve fiyat verileri EPİAŞ Şeffaflık Platformu'ndan; hava durumu verileri Open-Meteo tarihsel arşiv API'sinden elde edilmiştir. Veri seti 2021–2025 dönemini kapsamakta olup İstanbul, Ankara, İzmir, Antalya, Gaziantep, Samsun ve Erzurum'a ait saatlik meteorolojik gözlemleri içermektedir. Bu şehirler Türkiye'nin yedi farklı iklim bölgesini temsil edecek biçimde seçilmiştir. Modellerde sıcaklık, hissedilen sıcaklık, nem, bulutluluk, rüzgâr hızı ve yağış gibi fiziksel değişkenlerin yanı sıra saat, haftanın günü, ay, hafta sonu ve rüzgâr tatil bilgileri de kullanılmıştır.

Çalışmanın temel amacı: farklı modelleme yaklaşımlarını aynı veri seti üzerinde tutarlı koşullarda değerlendirerek tahmin kalitesini ölçmek. Bu doğrultuda yedi makine öğrenmesi algoritması, SARIMAX ve VARMAX zaman serisi modelleri ile CNN-LSTM ve Temporal Fusion Transformer mimarileri denenmiştir. Birden fazla modelin çıktısını birleştiren bir hibrit ensemble yaklaşımı da değerlendirmeye dahil edilmiştir.

Elektrik tüketimi tahmininde görece başarılı sonuçlar elde edilmiştir. Güçlü mevsimsel örüntüler ve takvim etkileri modellerin işini kolaylaştırmış; gecikmeli özellikler (özellikle lag_24 ve lag_168) açıklayıcı güce önemli katkı sağlamıştır. Fiyat tahmini ise başka bir tablo sunmuştur: 2022 yılında yaşanan ve fiyat ortalamasını yaklaşık beş katına çıkaran yapısal kırılma, ani fiyat sıçramaları ve yüksek oynaklık, tüm modellerin performansını ciddi biçimde sınırlandırmıştır. Bu nedenle fiyat tahmin modellerinde 2021 verisi eğitim setinden çıkarılmış; modeller yalnızca yapısal kırılma sonrası dönem üzerinde değerlendirilmiştir. Hibrit yaklaşım, her iki hedef değişkende de en istikrarlı sonuçları üretmiştir. Geliştirilen çerçevenin enerji planlaması, talep yönetimi ve piyasa analizi gibi alanlarda uygulanabilirliği değerlendirilmektedir.

ABSTRACT

This study examines short-term electricity consumption and electricity market clearing price (MCP) forecasting for Turkey with the contribution of meteorological variables. Hourly electricity generation, consumption, and price data were obtained from the EPIAŞ Transparency Platform; weather data were retrieved from the Open-Meteo historical archive API. The dataset spans the 2021–2025 period and includes hourly meteorological observations from Istanbul, Ankara, Izmir, Antalya, Gaziantep, Samsun, and Erzurum. These cities were selected to represent Turkey's seven distinct climate zones. Physical variables such as temperature, apparent temperature, humidity, cloud cover, wind speed, and precipitation were used in the models, along with time-based information including the hour, day of the week, month, weekends, and public holidays.

The main objective of the study is to measure forecast quality by evaluating different modeling approaches under consistent conditions on the same dataset. To this end, seven machine learning algorithms, SARIMAX and VARMAX time series models, as well as CNN-LSTM and Temporal Fusion Transformer architectures were tested. A hybrid ensemble approach combining the outputs of multiple models was also included in the evaluation.

Relatively successful results were achieved in electricity consumption forecasting. Strong seasonal patterns and calendar effects facilitated the models' task; lagged features (especially lag_24 and lag_168) made a significant contribution to explanatory power. Price forecasting, however, presented a different picture: a structural break in 2022 that raised the average price approximately fivefold, sudden price spikes, and high volatility severely constrained the performance of all models. Therefore, 2021 data was excluded from the training set in price forecasting models; the models were evaluated exclusively on the post-structural break period. The hybrid approach produced the most consistent results for both target variables. The applicability of the developed framework in areas such as energy planning, demand management, and market analysis is being evaluated.

1. GİRİŞ

Elektrik enerjisi depolanamaz. En azından şu an için, büyük ölçekte depolamak hem teknik hem ekonomik açıdan oldukça güçtür. Bu basit gerçek, üretim ile tüketim arasındaki dengenin anlık olarak korunmasını zorunlu kılar. Talebin önceden doğru tahmin edilmesi bu yüzden kritiktir; sadece bir optimizasyon meselesi değil, arz güvenliği ve sistem kararlılığı açısından temel bir operasyonel gerekliliktir.

Fiyat tahmini ise farklı ve çok daha karmaşık bir sorundur. Anlık talep, üretim kaynaklarının bileşimi, yenilenebilir enerji çıktısının değişkenliği, yakıt maliyetleri, piyasa katılımcılarının davranışları — bunların hepsi fiyatı birlikte biçimlendirir. Bu dinamik, fiyat serilerinde ciddi dalgalanmalara zemin hazırlamaktadır. Türkiye özelinde 2021–2022 geçişi bu duruma somut biçimde örnek olur: saatlik ortalama piyasa takas fiyatı yaklaşık 506 TL/MWh'tan 2.489 TL/MWh'a fırlamış, tek bir yılda serinin istatistiksel yapısı kökten değişmiştir. Bu tür yapısal kırılmaların varlığı, fiyat tahminini sıradan bir regresyon problemine indirgemek yerine, veri dönemlendirmesi ve model seçimi konusunda dikkatli tercihler yapmayı zorunlu kılmaktadır.

Son yıllarda veri altyapısının genişlemesi ve hesaplama kapasitesinin artmasıyla makine öğrenmesi ve derin öğrenme yöntemleri enerji tahmininde hızla yaygınlaştı. Ancak bu gelişmeler beraberinde kaçınılmaz bir soruyu getirdi: ek değişkenlerle, özellikle meteorolojik verilerle, tahmin performansı iyileştirilebilir mi? Sıcaklık ile elektrik tüketimi arasındaki ilişki sezgisel düzeyde açık görünse de farklı model yapılarında bu ilişkinin ne ölçüde yakalanabildiği hâlâ tartışmalıdır. Türkiye, Karadeniz kıyılarından Akdeniz iklimine, Ege'den yüksek Doğu Anadolu platosuna uzanan iklim çeşitliliğiyle bu soruyu test etmek için özellikle elverişli bir ortam sunmaktadır.

Bu çalışmada EPIAŞ'tan elde edilen saatlik elektrik verileri yedi şehre ait meteorolojik gözlemlerle birleştirilmiştir. Veri seti üzerinde kapsamlı bir ön işleme ve özellik mühendisliği süreci uygulanmış; ardından farklı model aileleri tüketim ve fiyat tahmini üzerinde karşılaştırmalı olarak değerlendirilmiştir.

1.1. Konunun Önemi

Doğru talep tahmini, enerji sistemlerinin verimli işletilmesi için temel bir girdidir. Tahmin hatası büyüdüğünde dengeleme maliyetleri yükselir; kapasite gereğinden fazla ayrıldığında ise kaynaklar israf edilir. Yenilenebilir enerji payının artmasıyla bu denge daha kırılgan hâle gelmiştir; güneş ve rüzgâr üretiminin değişkenliği sisteme yeni bir belirsizlik katmanı eklemektedir.

Meteorolojik koşullar bu tabloda doğrudan belirleyici bir rol üstlenmektedir. Yaz aylarında artan sıcaklık soğutma yükünü artırır; kış aylarında düşen sıcaklık ısıtma talebini yükseltir. Basit gibi görünen bu ilişki pratikte beklenenden daha karmaşık çıkabilmektedir. Keşifsel analiz aşamasında, sıcaklık ile elektrik tüketimi arasındaki çapraz korelasyonun eş zamanlı (lag=0) değil, 48 saat gecikmeli (lag=48) olarak tepe yaptığı gözlemlenmiştir. Bu bulgu binaların ısıl ataletiyle tutarlıdır: dış ortam sıcaklığındaki değişim iç ortama yavaş yansır, klima veya ısıtıcı tepkisi de buna bağlı olarak gecikir. Dolayısıyla modele yalnızca anlık sıcaklık yerine gecikmeli sıcaklık değerlerinin de dahil edilmesi gerekmektedir.

Fiyat tahmini söz konusu olduğunda meteorolojik değişkenlerin rolü daha az nettir. Analizde sıcaklığın fiyat üzerindeki doğrudan korelasyonu son derece zayıf ($r=0.072$) bulunmuştur. Bu, sezgisel açıdan şaşırtıcı görünmeyebilir; fiyat öncelikle arz-talep dengesi ve piyasa mekanizmaları üzerinden şekillenmektedir. Bununla birlikte, tüketim tahmini başarısının fiyat tahminini dolaylı olarak destekleyebileceği düşünüldüğünde her iki problemi aynı veri altyapısı üzerinde birlikte incelemek metodolojik açıdan anlamlı bir tercih olmaktadır.

1.2. Çalışmanın Amacı

Bu çalışmanın temel amacı, Türkiye'ye özgü bir kısa vadeli elektrik tüketimi ve fiyat tahmin çerçevesi geliştirmektir. Kapsam aşağıdaki temel araştırma adımlarını içermektedir:

EPIAŞ ve Open-Meteo kaynaklarından 2021–2025 dönemine ait saatlik elektrik ve meteorolojik verilerin derlenmesi ve birleştirilmesi,

Modellemeye uygun tutarlı bir veri yapısı oluşturmak üzere temizleme, birleştirme ve ön işleme adımlarının uygulanması,

Tüketim ve fiyat serilerinin zamansal dinamiklerinin, mevsimsel yapısının ve değişkenler arası ilişkilerinin keşifsel analiz yoluyla incelenmesi,

Makine öğrenmesi, zaman serisi ve derin öğrenme modellerinin aynı veri seti üzerinde tutarlı bir değerlendirme protokolüyle karşılaştırılması,

Hibrit ensemble yaklaşımının bireysel modellerle kıyaslandığında sağladığı performans farkının ölçülmesi,

Veri sızıntısı risklerinin kontrol altına alındığı, zaman bazlı bir değerlendirme çerçevesi kurulması.

1.3. Temel Kavramlar

Bu bölüm, çalışma boyunca başvurulacak temel kavramları tanımlamaktadır. Teknik birikimi farklı okuyucuların konuya hâkim olması amaçlanmaktadır.

1.3.1. Alan ve Veri Kavramları

Kısa Vadeli Yük Tahmini (STLF) (Short-Term Load Forecasting): Birkaç saatten bir haftaya uzanan zaman dilimlerinde elektrik tüketiminin tahmin edilmesidir. Üretim planlaması ve rezerv yönetiminde doğrudan kullanılır. "Kısa vade" tanımı literatürde tartışmalıdır; bu çalışmada 1–24 saatlik ufuk esas alınmıştır.

Piyasa Takas Fiyatı (PTF): EPIAŞ tarafından Türkiye Gün Öncesi Piyasası'nda her saat için belirlenen referans elektrik fiyatıdır. Arz ve talep tekliflerinin kesişiminde oluşur. Piyasa dinamiklerini izlemek için en doğrudan göstergedir.

Mevsimsellik: Zaman serilerinde belirli dönemlerde yinelenen düzenli örüntülerdir. Elektrik tüketiminde günlük, haftalık ve yıllık döngüler bir arada gözlemlenir. Bu üç katmanlı mevsimsellik, SARIMA gibi tek mevsimsellik varsayan modeller için ek bir güçlük oluşturmaktadır.

Yapısal Kırılma: Bir zaman serisinin istatistiksel özelliklerinin (ortalama, varyans veya otokorelasyon yapısı) belirli bir noktadan itibaren kalıcı olarak değişmesidir. Bu çalışmada 2021–2022 geçişinde fiyat serisinde belirgin bir yapısal kırılma saptanmıştır; bu bulgunun model eğitim dönemine ilişkin tercihlere yansıtılması gerekmektedir.

Dışsal Değişkenler (Exogenous Variables): Hedef değişkeni etkileyen ancak onun tarafından etkilenmeyen bağımsız girdilerdir. Bu çalışmada sıcaklık, nem, rüzgâr hızı ve tatil günleri bu kategoriye girmektedir. SARIMAX modelinde X harfi bu değişkenlere karşılık gelmektedir.

Gecikmeli Özellikler (Lag Features): Geçmiş zaman adımlarına ait değerlerin model girdisi olarak kullanılmasıyla türetilen değişkenlerdir. Çapraz korelasyon analizi, sıcaklık etkisinin tüketim üzerinde 48 saatlik gecikmeyle tepe yaptığını ortaya koymuştur. Benzer şekilde, bir önceki günün ve geçen haftanın aynı saatindeki tüketim değerleri (lag_24, lag_168) güçlü tahmin girdileri olarak öne çıkmaktadır.

1.3.2. Modelleme ve Metodoloji Kavramları

Makine Öğrenmesi: Veriden örüntü öğrenerek tahmin yapan algoritmaların genel adıdır. Doğrusal olmayan ilişkileri modelleyebilmesi, bu yöntemleri çok değişkenli enerji tahmin problemlerinde işlevli kılmaktadır. Öte yandan bazı algoritmalar (örneğin XGBoost), yorumlanabilirlik araçları (SHAP) eklenmediğinde kara kutu niteliği taşımaktadır.

Derin Öğrenme: Çok katmanlı yapay sinir ağlarına dayanan bir makine öğrenmesi yaklaşımıdır. Uzun vadeli bağımlılıkları yakalamada üstünlük sağlayabilir; ancak daha karmaşık yapısı her zaman daha iyi sonuç anlamına gelmez. Bu çalışmada da özellikle fiyat tahmininde bazı derin öğrenme modellerinin basit alternatiflerin gerisinde kaldığı gözlemlenmiştir.

Hibrit Modeller: Birden fazla modelin çıktısının birleştirildiği yapılardır. Hiçbir tek modelin her koşulda üstün gelmediği gerçeği göz önüne alındığında, farklı yöntemlerin tamamlayıcı güçlerini bir araya getirmek istatistiksel açıdan savunulabilir bir stratejidir. Yöntemler arasında ağırlıklandırma tercihinin de performansa etkisi bulunmaktadır.

Özellik Mühendisliği: Ham veriden model performansını artırabilecek yeni değişkenler türetme sürecidir. Bu çalışmada gecikmeli değerler, anomali göstergeleri (is_price_spike, is_price_dip) ve döngüsel takvim özellikleri bu sürecin ürünleridir. Doğru özellik seti çoğu zaman model seçiminden daha belirleyicidir.

Veri Sızıntısı (Data Leakage): Model eğitiminde geleceğe ait bilgilerin doğrudan ya da dolaylı olarak dahil edilmesidir. Zaman serisi problemlerinde bu risk özellikle yüksektir; ölçekleme ve imputasyon gibi adımlar tüm veri seti üzerinden yapıldığında sızıntı kaçınılmaz hâle gelir. Bu çalışmada her ön işleme adımı yalnızca eğitim verisi üzerinden gerçekleştirilmiş, test setine ayrı olarak uygulanmıştır.

Zaman Temelli Çapraz Doğrulama (TimeSeriesSplit): Kronolojik yapıyı koruyarak model performansını değerlendiren bir protokoldür. Standart k-katlı çapraz doğrulamanın aksine, eğitim verisi her zaman doğrulama verisinden önce gelir. Bu çalışmada 5 katlı TimeSeriesSplit kullanılmıştır.

1.3.3. Model Değerlendirme Metrikleri

Modellerin performansı birbirini tamamlayan hata ölçütleri üzerinden değerlendirilmiştir. Her metriğin farklı bir perspektif sunduğu ve tek bir metriğin yanıltıcı olabileceği göz önünde bulundurulmalıdır.

MAE (Mean Absolute Error): Tahmin hatalarının mutlak değerlerinin ortalamasıdır. Yorumlanması kolaydır ve aykırı değerlere RMSE kadar duyarlı değildir.

RMSE (Root Mean Square Error): Hata karelerinin ortalamasının karekökü olup büyük hataları orantısız biçimde cezalandırır. Ani fiyat sıçramalarının tahmininde bu özellik kritik önem taşımaktadır.

MAPE (Mean Absolute Percentage Error): Hatayı yüzde cinsinden ifade eder ve farklı ölçeklerdeki serilerin karşılaştırılmasını kolaylaştırır. Ancak gerçek değerlerin sıfıra yaklaştığı durumlarda güvenilirliğini yitirir; fiyat serilerinde dip fiyat dönemleri bu duruma yol açabilir.

sMAPE (Symmetric MAPE): MAPE'nin asimetri sorununa karşı geliştirilmiş bir alternatiftir. Gerçek ve tahmin değerlerinin ortalaması paydaya alınarak yönlü ceza etkisi giderilir.

NRMSE (Normalized RMSE): RMSE'nin serinin değer aralığına bölünmüş hâlidir. Ölçek farkı büyük olan tüketim ve fiyat serilerinin aynı çerçevede kıyaslanmasına olanak tanır.

2. LİTERATÜR TARAMASI

2.1. Klasik İstatistiksel ve Zaman Serisi Yöntemleri

Enerji tahmini literatürü klasik zaman serisi yöntemleriyle başlar. Bu yöntemlerin iki belirgin avantajı vardır: yorumlanabilirlik ve düşük hesaplama maliyeti. Ancak doğrusal olmayan ilişkileri yakalamadaki sınırlılıkları uzun süredir tartışılmaktadır.

Box ve diğerleri [1] tarafından sistematik biçimde ortaya konan ARIMA modeli, bu alandaki temel referanstır. Mevsimsel bileşenlerin eklenmesiyle SARIMA, ardından dışsal değişkenlere kapı açan SARIMAX geliştirilmiştir. SARIMAX, sıcaklık ve tatil günleri gibi dışsal faktörleri yapıya dahil etmesiyle sadece geçmiş tüketim değerlerine dayanan modellerin göremediği örüntülerin yakalanmasını mümkün kılmaktadır. Elamin ve Fukushima [2], bu yaklaşımı uygulamada da doğrulamıştır: sıcaklık ve tatil etkilerinin talep üzerinde ölçülebilir bir iz bıraktığı gösterilmiştir.

Basit yöntemleri küçümsemek gerekir. Taylor ve McSharry [3], çift mevsimsel üstel düzleştirme (double seasonal exponential smoothing) modelinin İngiltere yük verisi üzerinde 1 saatlik ufukta ARIMA ve sinir ağı modellerini geçtiğini göstermiştir. Bu bulgunun mesajı nettir: model karmaşıklığını artırmak, kısa vadeli tahmin problemlerinde her zaman kazanım sağlamaz. Kullanılan veri frekansı ve tahmin ufku bu eşiklemeleri belirler; dolayısıyla bir metodun "üstünlüğü" ancak belirli bir veri yapısı bağlamında anlam taşır.

Fiyat tahmini söz konusu olduğunda tablo kökten değişir. Weron [4], elektrik spot fiyatlarının "stilize gerçekler" (stylized facts) olarak adlandırılan özgün istatistiksel özellikler taşıdığını kapsamlı biçimde belgelemiştir: mevsimsel döngülerin üst üste binmesi, süreklilik sağlayan ortalamaya dönüş (mean-reversion), uzun hafıza ve saatlerce sürebilen ani fiyat sıçramaları. Bu yapı, hisse senedi veya döviz kuru serilerinden bile farklıdır; GARCH ailesi modeller bile ani sıçramaların büyüklüğünü tutarlı biçimde tahmin edemez. Bu çalışmada da benzer bir tablo gözlemlenmiştir: özellikle 2022 yapısal kırılmasını kapsayan dönemlerde sabit parametrelili SARIMAX'ın tahmin hataları belirgin biçimde yükselmiştir. Bu durum, fiyat modellerini yalnızca yapısal kırılma sonrası dönemle sınırlandırma kararının gerekçesini oluşturmaktadır.

2.2. Makine Öğrenmesi Yaklaşımları

Makine öğrenmesi yöntemleri, doğrusal olmayan ilişkileri öğrenme kapasiteleri sayesinde enerji tahmininde giderek daha fazla kullanılmaktadır. Bu modellerin gücü yalnızca algoritma seçiminden değil, büyük ölçüde özellik setinin kalitesinden kaynaklanmaktadır. İyi tasarlanmış bir özellik kümesi, ortalama bir modeli güçlü bir modele dönüştürebilmektedir.

Random Forest, Breiman [5] tarafından önerilmiştir. Birden fazla karar ağacının paralel eğitilerek çıktılarının ortalamasının alınmasına dayanır. Gürültüye karşı dirençlidir ve aşırı öğrenme riskini sınırlandırır. Enerji verilerinde bu özellikler değerlidir; çünkü gerçek dünya verileri her zaman temiz ve tutarlı gelmez.

Gradient Boosting ise farklı bir strateji izler. Modeller sıralı biçimde öğrenir; her yeni model bir öncekinin hatalarını düzeltmeye çalışır. Bu yaklaşımdan türeyen XGBoost (Chen ve Guestrin [6]) ve LightGBM (Ke ve diğerleri [7]), büyük veri setlerinde hem yüksek doğruluk hem de hız sağlayarak alan çalışmalarında yaygın araçlara dönüşmüştür. Bu çalışmada 43.824 saatlik veri boyutu göz önüne alındığında LightGBM'in eğitim süresi avantajı özellikle belirgin olmuştur.

Özellik mühendisliği bu süreçte kritik bir rol oynamaktadır. Madrid ve diğerleri [8], gecikmeli değişkenler ve takvim özelliklerinin modele katılmasının tahmin doğruluğunu anlamlı ölçüde

artırdığını göstermiştir. Bu çalışmada da benzer bir bulguyla karşılaşmıştır; özellikle lag_24 ve lag_168 özellikleri modelin açıklayıcı gücüne belirgin katkı sağlamıştır.

Yorumlanabilirlik ayrı bir mesele olarak öne çıkmaktadır. Enerji piyasalarında karar vericiler çoğunlukla salt tahmin sayısının ötesinde, o tahmini neyin yönlendirdiğini bilmek ister. Lundberg ve Lee [9] tarafından geliştirilen SHAP yöntemi bu açıdan değerli bir araç sunmaktadır: model davranışını bireysel özellik katkıları üzerinden ayrıştırarak hangi değişkenin hangi tahmini ne yönde etkilediğini görselleştirmeye olanak tanır.

2.3. Derin Öğrenme Mimarileri

Derin öğrenme modellerinin zaman serisi tahmininde her durumda üstün gelmediği artık yaygın biçimde kabul görmektedir. Bununla birlikte, belirli mimarilerin belirli problem yapılarına iyi uyduğu görülmektedir.

Hochreiter ve Schmidhuber [10] tarafından geliştirilen LSTM, tekrarlayan sinir ağlarının uzun vadeli bağımlılık öğrenmedeki sınırlılıklarını gidermek amacıyla tasarlanmıştır. Kapı mekanizmaları sayesinde model, hangi bilgiyi saklayıp hangisini geçeceğine bağlamsal olarak karar verebilir. Kong ve diğerleri [11], LSTM tabanlı modellerin kısa vadeli yük tahmininde geleneksel yöntemlere kıyasla ölçülebilir iyileşmeler sağladığını göstermiştir. Marino ve diğerleri [12] ise girdi normalizasyonu ve pencere boyutu seçiminin model performansı üzerindeki bağımsız etkisine dikkat çekmiştir; doğru hazırlanmış veri olmadan mimari tek başına fazlasını yapamamaktadır.

Temporal Fusion Transformer (TFT), Lim ve diğerleri [13] tarafından önerilmiştir. Geçmiş değerleri, geleceği önceden bilinen değişkenleri (tatil günleri, saat bilgisi gibi) ve statik bağlam özelliklerini tek yapı içinde işleyebilmesi onu diğer mimarilerden ayırmaktadır. Dikkat mekanizması ayrıca yorumlanabilirlik sunmaktadır: model hangi geçmiş dönemlere ve değişkenlere daha yüksek ağırlık atadığını açık biçimde ortaya koyar. Bu özellik, özellikle ani fiyat sıçramaları gibi istisnai olayların analizinde değer taşımaktadır.

Öte yandan Lago ve diğerleri [14], elektrik fiyat tahmininde LSTM ve GRU modellerinin bazı dönemlerde daha basit yöntemlerin gerisinde kaldığını raporlamıştır. Bu çalışmada da benzer bir tabloya rastlanmış; özellikle fiyat tahmininde derin öğrenme modellerinin tutarsız performans sergilediği gözlemlenmiştir. Daha karmaşık modeller her zaman daha iyi sonuç üretmez; veri miktarı ve veri kalitesi bu süreçte belirleyici olmaktadır.

2.4. Hibrit Tahmin Çerçeveleri

Tek bir modelin tüm koşullarda üstün gelmeyeceği fikri, ensemble ve hibrit yaklaşımlara olan ilgiyi doğal olarak artırmıştır. Farklı modeller farklı türde hatalar üretir; bu hataların bir kısmı birbirini telafi eder ve birleşik tahmin daha kararlı bir yapı kazanır.

Makridakis ve diğerleri [15] tarafından düzenlenen M4 yarışması bu argümanı büyük ölçekli kanıtlarla destekledi. Birinci sırayı alan Smyl [16] yaklaşımı, üstel düzleştirme ile sinir ağı bileşenlerini harmanlamaktaydı. Yalnızca derin öğrenmeye dayanan yöntemlerin geride kalması araştırmacılar arasında tartışma yarattı; bu sonuç "daha karmaşık her zaman daha iyi değildir" argümanını güçlü biçimde destekler.

Bontempi ve diğerleri [17], ensemble yöntemlerin farklı veri yapılarında daha kararlı sonuçlar ürettiğini göstermiştir. Ghofrani ve diğerleri [18], yük tahmininde çoklu model kombinasyonlarının tek yöntemli yaklaşımlardan sistematik biçimde üstün çıktığını raporlamıştır. Fan ve diğerleri [19] ise dinamik hibrit yapıların önemine dikkat çekmiş; farklı dönemlerde farklı modellerin öne geçebileceğini, bu nedenle sabit ağırlıklandırma şemalarının

yetersiz kalabileceğini vurgulamıştır. Bu nokta uygulamada sıkça göz ardı edilmektedir ve bu çalışmada da ağırlıklandırma stratejisinin model performansı üzerindeki etkisi ayrıca test edilmiştir.

2.5. Türkiye'ye Yönelik Çalışmalar ve Literatür Boşluğu

Türkiye elektrik piyasasına yönelik tahmin çalışmaları son yıllarda sayıca artmıştır. Piyasa serbestleşmesi, hızla büyüyen yenilenebilir enerji kapasitesi ve artan talep bu ilgiyi besleyen başlıca etkenlerdir. Ancak mevcut literatür incelendiğinde bazı yapısal boşluklar dikkat çekmektedir.

Çalışmaların büyük çoğunluğu ya yalnızca tüketim ya da yalnızca fiyat tahminini ele almaktadır. İkisini aynı veri ve metodoloji çerçevesinde karşılaştıran çalışma sayısı oldukça sınırlıdır. Meteorolojik veri kullanımı da genellikle tek bir şehir ya da dar bir bölgeyle kısıtlı kalmaktadır. Türkiye'nin Karadeniz'den Akdeniz'e, Doğu Anadolu'dan Ege kıyılarına uzanan iklim çeşitliliği göz önüne alındığında, tek bölgesel bir yaklaşımın ürettiği sonuçların genellenebilirliği tartışmaya açıktır.

Makine öğrenmesi, derin öğrenme ve klasik zaman serisi yöntemlerini aynı veri seti ve değerlendirme sistemi üzerinde birlikte karşılaştıran çalışmalar da oldukça azdır. Bu eksikliğin pratik sonucu şudur: bir yöntemin diğerinden iyi çıkması, çoğunlukla algoritma farkından değil veri hazırlık ya da değerlendirme protokolündeki tercihlerden kaynaklanmaktadır; ancak metodoloji standart olmadığı için bunu ayırt etmek güçleşmektedir.

Bu çalışma söz konusu boşlukları doğrudan hedeflemektedir. Yedi farklı şehre ait meteorolojik veriler kullanılarak Türkiye genelinin daha iyi temsil eden bir veri altyapısı oluşturulmuştur. Tüketim ve fiyat tahmini aynı çerçeve içinde ele alınmış; farklı model aileleri tutarlı bir karşılaştırma düzeniyle değerlendirilmiştir. 2022 yapısal kırımının fiyat modellerine yansıtılması ve hibrit yaklaşımın bu bağlamda uygulanması, çalışmanın özgün katkıları arasındadır.

3. VERİ SETİ, ÖN İŞLEME VE KEŞİFSEL ANALİZ


Projenin veri altyapısı iki ana kaynaktan oluşmaktadır: EPİAŞ Şeffaflık Platformundan elde edilen saatlik elektrik üretim-tüketim-fiyat verileri ve Open-Meteo tarihsel hava arşivi API'sinden indirilen şehir bazlı saatlik meteorolojik veriler. İki veri grubunun zaman ekseninde birleştirilmesiyle nihai modelleme veri seti oluşturulmuş; gerekli ön işleme, özellik mühendisliği ve keşifsel analiz adımları uygulanmıştır.

3.1. Veri Kaynakları

Elektrik verileri: 2021-01-01 00:00 ile 2025-12-31 23:00 arasındaki tüm saatleri kapsayan veri seti EPİAŞ Şeffaflık Platformundan [20] indirilmiştir. Beklenen gözlem sayısı 43.824 olup birleştirme sonrası gerçek satır sayısının bu değere eşit olduğu doğrulanmıştır; saatlik zaman indeksinde boşluk bulunmamaktadır. Fiyat değişkeninde başlangıçta 17 eksik değer saptanmıştır; bu değerler zaman bazlı doğrusal interpolasyon ile tamamlanmıştır.

Hava durumu verileri: İstanbul, Ankara, İzmir, Antalya, Samsun, Gaziantep ve Erzurum için Open-Meteo tarihsel arşiv API'si [21] üzerinden saatlik veriler indirilmiştir. Bu şehirler sırasıyla Marmara, İç Anadolu, Ege, Akdeniz, Karadeniz, Güneydoğu Anadolu ve Doğu Anadolu iklim bölgelerini temsil edecek biçimde seçilmiştir. Kullanılan meteorolojik değişkenler: sıcaklık (°C), bağıl nem (%), hissedilen sıcaklık (°C), bulut örtüsü (%), rüzgâr hızı (km/h) ve yağış (mm).

Hava değişkenlerinin ülke düzeyinde temsili bir sinyale dönüştürülmesi için nüfus temelli ağırlıklandırma yöntemi uygulanmıştır. Bu tercih, büyük nüfus merkezlerindeki elektrik talebinin toplam tüketim içindeki payını dolaylı olarak yansıtmaya amacı taşımaktadır. Doğrudan tüketim bazlı ağırlıklandırma (TEİAŞ bölge verileri kullanılarak) metodolojik açıdan daha savunulabilir bir alternatif olabilirdi; ancak bölgesel tüketim verisine erişim kısıtları bu yola başvurmayı engellemiştir. Kullanılan ağırlıklar TÜİK 2023 ADNKS verisinden türetilmiş olmakla birlikte, tek bir şehrin aşırı baskın olmasını önlemek amacıyla oransal dağılım uygulanmıştır: İstanbul %47,9, Ankara %17,5, İzmir %13,3, Antalya %8,1, Gaziantep %6,6, Samsun %4,2, Erzurum %2,4. Gelecek çalışmalarda tüketim bazlı ağırlıkların kullanımı öncelikli bir iyileştirme olarak değerlendirilebilir.



Şekil 3.1: Saatlik Elektrik Tüketimi

Şekil 3.1, 2021–2025 dönemine ait saatlik elektrik tüketim serisini göstermektedir. Grafik incelendiğinde birkaç temel özellik dikkat çekmektedir. Öncelikle, serinin belirgin bir günlük döngüsel yapısı bulunmakta; gece saatlerinde (00:00–05:00) düşen, sabah ile akşam saatlerinde (08:00–10:00 ve 18:00–21:00) yoğunlaşan bir örüntü açıkça görülmektedir. İkinci olarak, mevsimsel dalgalanmalar göze çarpmaktadır: yaz aylarında soğutma yükü, kış aylarında ısıtma talebi serinin zirvelerini oluşturmaktadır. Üçüncüsü, 2021–2025 dönemi boyunca tabanda yavaş ve kademeli bir büyüme eğilimi seçilmekte; bu durum Tablo 3.3'teki yıllık ortalama artışlarla örtüşmektedir. Serinin belirgin döngüsellliği, lag_24 (bir önceki günün aynı saati) ve

lag_168 (geçen haftanın aynı saati) gibi gecikme değişkenlerinin model girdisi olarak seçilmesinin temel görsel dayanak noktasını oluşturmaktadır.

3.2. Ön İşleme Adımları

Veri birleştirme: Elektrik üretim, tüketim ve fiyat verileri ayrı CSV dosyalarından okunmuş; tarih ve saat alanları birleştirilerek Türkiye yerel saatine göre zaman damgaları oluşturulmuştur. Türkçe sayı formatından (nokta-virgül ayrımı) kaynaklanan biçim sorunları giderilmiştir.

Eksik değer giderme: Fiyat değişkenindeki 17 eksik değer zaman indeksine dayalı doğrusal interpolasyonla tamamlanmıştır. Saatlik elektrik fiyatlarının kısa vadede görece sürekli bir yapı sergilemesi bu tercih için temel gerekçeyi oluşturmaktadır. Alternatif olarak önceki güne ait aynı saat değeriyle doldurma (lag_24 imputasyonu) da değerlendirilmiş, ancak eksik saatlerin yalnızca 17 ile sınırlı olması iki yaklaşım arasındaki farkı göz ardı edilebilir kılmıştır.

Hava verisi dönüşümü: Şehir bazındaki meteorolojik değişkenler geniş formattan pivot tabloya dönüştürülmüş, ardından nüfus ağırlıklarıyla ağırlıklı ortalama hesaplanarak ulusal düzeyde tekil değişkenler üretilmiştir. Ağırlık toplamının 1.0000'e eşit olduğu doğrulanmıştır.

Takvimsel değişkenler: Saat (0–23), haftanın günü (0–6), ay (1–12), hafta sonu ve resmî tatil göstergeleri oluşturulmuştur. Resmî tatil bilgisi Python'un holidays kütüphanesinin Turkey modülüyle üretilmiştir (2021–2025 yıllarını kapsayan tam tatil takvimi). Dini bayramların hareketli tarihleri bu kütüphane tarafından hicri takvim dönüşümü yoluyla otomatik olarak hesaplanmaktadır. Tatil günü oranı %3,8, hafta sonu oranı %28,6 olarak hesaplanmıştır.

Anomali göstergeleri: Saatlik piyasa takas fiyatlarında yaşanan aşırı dalgalanmaların model tarafından ayrı bir örüntü olarak işlenebilmesi amacıyla iki gösterge değişkeni türetilmiştir. Fiyatın 95. yüzdelik dilimini (3.649,3 TL/MWh) aştığı saatler için is_price_spike, 5. yüzdelik diliminin (308,4 TL/MWh) altına düştüğü saatler için is_price_dip değişkenleri oluşturulmuştur. Her biri yaklaşık 2.192 saate (%5,0) karşılık gelmektedir.

Yapısal kırılma ve eğitim dönemi kararı: Fiyat serisinde 2022 yılında saptanan yapısal kırılma, model eğitim dönemine ilişkin kritik bir metodolojik tercih gerektirmiştir. 2021 yılına ait ortalama fiyat (505,9 TL/MWh), 2022–2025 döneminin yaklaşık beşte biri düzeyindedir. Bu denli farklı istatistiksel rejimleri tek bir eğitim seti içinde kullanmak, modelin kırılma öncesi döneme ait örüntüleri öğrenerek güncel piyasa koşullarına uyumsuz hâle gelmesi riskini doğurmaktadır. Bu nedenle fiyat tahmin modelleri 2022–2025 verisi üzerinde eğitilmiş; tüketim modelleri ise mevsimsel örüntünün 2021'de de tutarlı olması nedeniyle tam 5 yıllık veriyle çalıştırılmıştır.

Tablo 3.1: Veri Setindeki Değişkenler

Değişken	Açıklama	Birim
uretim_mwh	Saatlik elektrik üretimi	MWh
tuketim_mwh	Saatlik elektrik tüketimi	MWh
fiyat_tl	Elektrik piyasa takas fiyatı (PTF)	TL/MWh
sicaklik	Ağırlıklı ortalama hava sıcaklığı	°C
hissedilen_sicaklik	Ağırlıklı ortalama hissedilen sıcaklık	°C

Değişken	Açıklama	Birim
nem	Ağırlıklı ortalama bağıl nem oranı	%
bulut_ortus	Ağırlıklı ortalama bulut örtüsü oranı	%
ruzgar_hizi	Ağırlıklı ortalama rüzgâr hızı	km/h
yagis	Ağırlıklı ortalama yağış miktarı	mm
saat	Günün saati	0–23
haftanın_gunu	Haftanın günü (0=Pzt, 6=Paz)	0–6
ay	Yılın ayı	1–12
is_weekend	Hafta sonu göstergesi	0/1
is_holiday	Resmî tatil göstergesi	0/1
is_price_spike	Aşırı yüksek fiyat göstergesi (>P95)	0/1
is_price_dip	Aşırı düşük fiyat göstergesi (<P5)	0/1

	Datetime	uretim_mwh	tuketim_mwh	fiyat_tl	sicaklik	hissedilen_sicaklik	nem	bulut_ortus	ruzgar_hizi	yagis	saat	haftanın_gunu	ay	is_weekend	is_holiday
0	2021-01-01 00:00:00	29488.11	29489.46	259.39	9.79	6.91	77.41	59.42	13.50	0.01	0	4	1	0	1
1	2021-01-01 01:00:00	28065.76	28067.11	234.13	9.88	6.58	75.14	34.92	15.98	0.01	1	4	1	0	1
2	2021-01-01 02:00:00	26527.08	26527.08	215.25	9.58	6.37	77.43	37.49	15.81	0.01	2	4	1	0	1
3	2021-01-01 03:00:00	25327.19	25327.19	219.24	9.55	6.26	78.35	41.92	16.13	0.01	3	4	1	0	1
4	2021-01-01 04:00:00	24719.72	24719.72	209.81	9.32	6.26	79.02	36.95	14.82	0.06	4	4	1	0	1


Şekil 3.2: Veri Seti Örneği

Şekil 3.2, ön işleme sonrası birleşik veri setinin ilk satırlarını göstermektedir. Görüntü, veri entegrasyonunun doğru çalıştığını birkaç açıdan doğrular. Öncelikle, Datetime sütununu kullanarak yapılan outer merge sonrasında elektrik üretim, tüketim ve fiyat sütunlarında NaN değer bulunmaması birleştirme kalitesinin başarılı olduğunu göstermektedir. İkincisi, meteorolojik değişkenlerin örnek değerleri beklenen fiziksel aralıklarda yer almaktadır: 2021 Ocak başında ağırlıklı ortalama sıcaklık yaklaşık 9,8°C, nem %77 düzeyindedir. Üçüncüsü, takvim değişkenlerinin doğru üretildiği görülmektedir: 2021-01-01 00:00 saati gerçekten tatil günü (is_holiday=1) ve hafta sonu değil (is_weekend=0) olarak işaretlenmiştir. Bu tablo, veri hattının uygulama için hazır olduğunu ve herhangi bir format veya birleştirme hatasının olmadığını teyit etmektedir.

3.3. Keşifsel Analiz Bulguları

Veri setindeki değişkenlerin dağılımları ve birbirleriyle olan ilişkileri Seaborn ve Matplotlib kütüphaneleri ile görselleştirilmiştir. Bu bölümde yalnızca modelleme kararlarını doğrudan etkileyen bulgular aktarılmaktadır.

3.3.1. Saatlik Ortalama Tüketim ve Fiyat Profili




Şekil 3.3: Saatlik Ortalama Tüketim ve Fiyat Profili

Tüketim eğrisi sabah 05:00 sularında en düşük seviyeye inerken, günün başlamasıyla hızla yükselmekte ve akşam saatlerinde günlük zirveye ulaşmaktadır. Bir ayrıntı dikkat çekmektedir: öğle saatlerinde (12:00–13:00 arası) fiyat eğrisi beklenmedik biçimde keskin bir çöküş sergiliyorken tüketim nispeten sabit kalıyor. Büyük olasılıkla bu saatlerde güneş enerjisi üretiminin ani yükselmesi arz tarafını beslemekte ve fiyatı baskılamaktadır. Bu, ilerleyen aşamalarda fiyat modellerinde arz tarafı değişkenlerinin ya da saatlik güneş üretim tahmininin bağımsız bir girdi olarak denenmesi gerekebileceğine işaret eden somut bir gözlemdir.


Grafik, günlük tahmin probleminde lag_24 ve lag_168 gecikmelerinin neden güçlü tahmin değişkenleri olduğunu da görsel düzeyde desteklemektedir: serinin belirgin bir günlük ve haftalık döngüsellik taşıdığı açıktır.

3.3.2. Tüketim Dağılımı ve İki Tepeli Yapı



Şekil 3.4: Tüketim Dağılımı


Tüketim değişkeninin (tuketim_mwh) histogramı incelendiğinde, yaklaşık 32.000 ve 40.000 MWh düzeyinde olmak üzere iki belirgin yoğunlaşma bölgesi dikkat çekmektedir. Bu iki tepeli yapı, iki farklı talep rejiminin izini taşıyor: gece/hafta sonu/mevsim-arası düşük tüketim dönemleri ile gündüz/hafta içi/yaz-kış puant dönemleri. Sonuç olarak bu seride normallik varsayımı tutmaz. Regresyon modellerinin hata dağılımlarını kontrol ederken ve ki-kare ya da t-testleri uygulamak gerektiğinde bu yapı akılda tutulmalıdır.



Şekil 3.5: Fiyat Dağılımı

Fiyat değişkeninin (fiyat_tl) dağılımı ise çok daha karmaşık bir tablo sunmaktadır: düşük fiyat dönemlerinde yoğun bir yığılma, ardından 2.000–3.000 TL/MWh bandında ikinci bir tepe ve bunun yanı sıra belirgin bir sağ kuyruk bulunmaktadır. Bimodal görünüm, 2021'in düşük fiyat rejimiyle 2022–2025'in yüksek fiyat rejiminin aynı histogramda birleşmesinden kaynaklanmaktadır. Bu, fiyat modellerinde 2021 verisinin ayrı tutulması gerektiğinin ek bir göstergesidir.

3.3.3. Sıcaklık ve Elektrik Tüketimi İlişkisi




Şekil 3.6: Sıcaklık ve Elektrik Tüketimi İlişkisi

Sıcaklık ile elektrik tüketimi arasındaki ilişki doğrusal değildir. Scatter grafiği, 15–20°C aralığında tüketimin görece düşük ve dağınık olduğunu; bu aralığın altında ve üzerinde ise belirgin bir artış eğiliminin bulunduğunu ortaya koymaktadır. Bu "U" biçimli örüntü, ısıtma ve soğutma yüklerinin termal konfor bölgesinin her iki yanında tüketimi yukarı ittiğini

yansıtmaktadır. Yüksek sıcaklık ucundaki (30°C üzeri) artış, düşük sıcaklık ucuna kıyasla daha dik bir eğimle gerçekleşmektedir; Türkiye'de klima kullanımının ısıtmaya göre daha elektrik-yoğun olmasıyla tutarlı bir bulgudur.

Bu doğrusal olmayan yapı, Doğrusal Regresyon'un bu veri seti üzerinde sınırlı performans sergilemesini beklemek için makul bir gerekçe oluşturmaktadır. Karar ağacı tabanlı yöntemler (XGBoost, LightGBM, Random Forest) eşik değer öğrenerek bu yapıyı doğal olarak modelleyebilmektedir.

3.3.4. Korelasyon Analizi ve Çoklu Bağlantı



Şekil 3.7: Korelasyon Matrisi

Korelasyon matrisi, modelleme açısından birkaç önemli bulgu ortaya koymaktadır. Öncelikle, sıcaklık ve hissedilen_sıcaklık arasındaki korelasyon 0.99 olarak hesaplanmıştır. Bu düzeyde bir korelasyon, her iki değişkenin modele birlikte dahil edilmesinin ağaç bazlı modeller için fiili bir sorun yaratmayacağını, ancak regresyon tipi modellerde çoklu bağlantı (multicollinearity) sorununa yol açabileceğini düşündürmektedir. Bu nedenle doğrusal modellerde yalnızca birinin (tercihan hissedilen sıcaklığın) kullanılması önerilmektedir.

Fiyatın hava durumu değişkenleriyle doğrudan korelasyonu zayıf çıkmıştır (sıcaklık: 0,072, nem: -0,023). Bu şaşırtıcı değil; fiyat piyasa mekanizması üzerinden şekilleniyor, hava koşulları ise ancak tüketim üzerinden bunu dolaylı etkiliyor. Ne var ki korelasyon matrisi bu dolaylı zinciri yakalayamaz. Doğrusal korelasyonun burada bize söyleyebileceği neredeyse hiçbir şey yok. Bu, aracı değişken (mediator) yapıları için beklenen bir tablodur.

3.3.5. Durağanlık Testleri


Tablo 3.2: Durağanlık Testleri

Değişken	ADF p-değeri	KPSS p-değeri	Yorum	Önerilen d
Tüketim	0.000	0.010	Trend-Durağan	0
Fiyat	0.212	0.010	Durağan Değil	1
Üretim	0.000	0.010	Trend-Durağan	0

Tüketim, üretim ve fiyat serileri Augmented Dickey-Fuller (ADF) ve KPSS testleriyle durağanlık açısından değerlendirilmiştir. Her üç seri de benzer bir örüntü sergilemiştir: ADF testi birim kök hipotezini (H_0 : seri birim kök taşır) reddetmiştir ($p=0.000$); bu sonuç serilerin birim kök içermediğine, dolayısıyla ADF ölçütü açısından durağan olduğuna işaret etmektedir. Buna karşın KPSS testi durağanlık hipotezini (H_0 : seri durağandır) reddetmiştir ($p=0.01$). Bu çelişkili tablo, literatürde "trend-durağan" (trend-stationary) olarak adlandırılan bir duruma işaret etmektedir: seri uzun dönemli bir trendi ya da uzun hafıza yapısını bünyesinde barındırmaktadır. Tablodaki KPSS p-değerlerinin hepsinin 0,010 olarak görünmesi bir tesadüf değildir; statsmodels kütüphanesi bu değeri raporlayabileceği alt sınır olarak döndürmektedir, yani gerçek p-değeri 0,010 veya daha küçüktür ($p \leq 0,01$).

Bu sonucun modelleme kararlarına pratik yansıması serilere göre farklılaşmaktadır. Tüketim serisi ADF ✓ / KPSS ✗ örüntüsü göstererek trend-durağan bir yapı sergilemiştir; bu durumda diferansiyelleme ($d=1$) yerine SARIMAX modelinde trend parametresi ($\text{trend}='ct'$) kullanılmış ve $d=0$ seçilmiştir. Fiyat serisi ise her iki testin de durağanlık hipotezini reddetmesiyle gerçek anlamda durağan olmayan bir seri olarak değerlendirilmiş; bu nedenle SARIMAX modelinde birinci fark ($d=1$) uygulanmıştır. Diferansiyellenmiş fiyat serisinin ADF testinde durağan çıktığı doğrulanmıştır ($p=0.000$). Üretim serisi de tüketim serisiyle benzer bir trend-durağan örüntü göstermiştir. Makine öğrenmesi modellerinde ise fark almak yerine zaman bazlı özellikler (yıl trendi, gecikmeli değerlerin hareketli ortalaması) üretilerek bu yapı dolaylı olarak kontrol altına alınmıştır.

3.3.6. Otokorelasyon ve Çapraz Korelasyon Analizi




Şekil 3.8: ACF – PACF Testleri

Saatlik otokorelasyon katsayıları, her iki hedef seride de geçmiş gözlemlerin yüksek bilgi taşıdığını açıkça ortaya koymaktadır. Tüketimde lag_1: $r=0.967$, lag_24: $r=0.868$, lag_168: $r=0.879$; fiyatta ise lag_1: $r=0.945$, lag_24: $r=0.864$, lag_168: $r=0.863$ olarak hesaplanmıştır. Bu değerler, özellikle günlük (24 saatlik) ve haftalık (168 saatlik) gecikme yapılarının model girdisi olarak dahil edilmesini kuvvetle desteklemektedir.

Çapraz korelasyon analizi, sıcaklığın tüketim üzerindeki etkisinin eş zamanlı değil, 48 saatlik bir gecikmeyle ($r=0.414$) tepe yaptığını ortaya koymuştur. Bu bulgu binaların ısıl ataletiyle tutarlıdır ve modele yalnızca anlık sıcaklık yerine lag_24_sıcaklık ve lag_48_sıcaklık değişkenlerinin eklenmesi gerektiğine işaret etmektedir. Fiyat için ise sıcaklığın doğrudan gecikmeli etkisi anlamlı bir eşiğin ($r>0.20$) altında kalmıştır; bu da sıcaklığın fiyatı dolaylı bir zincir üzerinden etkilediği yorumunu desteklemektedir.

3.3.7. Sıcaklık Etkisi — Optimal Lag Tespiti (Çapraz Korelasyon)




Şekil 3.9: Sıcaklık Etkisi Grafikleri

Şekil 3.9, sıcaklık ile tüketim/fiyat değişkenleri arasındaki çapraz korelasyon fonksiyonunu -48 ile $+48$ saatlik lag aralığında göstermektedir. Turuncu kesikli çizgi $\pm 0,20$ anlamlılık eşiğini,

kırmızı dikey çizgi ise tepe korelasyonun olduğu gecikme değerini göstermektedir. Tüketim grafiğinde (sol panel) en dikkat çekici bulgu, korelasyonun eş zamanlı (lag=0) değil, lag=+48 noktasında ($r=0,414$) doruk yapmasıdır. Bu gecikme yapısı, binalardaki ısıl ataletin etkisiyle tutarlıdır: dış sıcaklık değişimi iç ortama hemen yansımaz, iklimlendirme sistemleri ise bu gecikmeli tepkiyi izler. Bunun pratik sonucu, sıcaklık değerinin lag_24 ve lag_48 versiyonlarının model girdisi olarak dahil edilmesinin faydalı olacağıdır; anlık sıcaklık tek başına yeterli değildir. Fiyat grafiğinde (sağ panel) ise tüm gecikme değerleri boyunca korelasyon $\pm 0,20$ eşliğinin altında kalmıştır. Bu sonuç, sıcaklığın fiyat üzerinde anlamlı bir doğrudan gecikme etkisi taşımadığını göstermektedir; fiyat çok daha karmaşık bir arz–talep mekanizmasıyla şekillenmektedir.

3.3.8. Trend ve Yapısal Kırılma



Şekil 3.10: Trend ve Yapısal Kırılma Grafikleri

Yıllık istatistikler, fiyat serisindeki yapısal değişimi somut biçimde ortaya koymaktadır. Ortalama saatlik fiyat 2021'de 505,9 TL/MWh iken 2022'de 2.488,8 TL/MWh'a yükselmiş, ardından 2023 ve 2024'te bir miktar gerilemiş, 2025'te ise yeniden 2.603,4 TL/MWh düzeyine çıkmıştır. Tüketim tarafında ise çok daha istikrarlı bir seyir dikkat çekmektedir: ortalama saatlik tüketim 2021'de 37.305 MWh'tan 2025'te 40.241 MWh'a yavaş ve kademeli bir artış sergilemiştir.

Sayılar iki hedef değişkenin ne kadar farklı problemler olduğunu açıkça ortaya koyuyor. Tüketimde yıllık büyüme düzgün ve öngörülebilir: 2021'de 328,8 TWh'tan 2025'te 352,5 TWh'a yaklaşık %7'lik bir artış. Fiyatta ise durum başka; tek bir yılda beş katına çıkan, ardından iki yıl boyunca dalgalanan bir seri. Bu iki değişkeni benzer yöntemlerle modellemek doğru bir yaklaşım olmaz.

Tablo 3.3: Yıllık İstatistiksel Özet

Yıl	Ort. Tüketim (MWh)	Ort. Fiyat (TL/MWh)	Fiyat Std. Sapma
2021	37.305	505,9	248,3
2022	36.965	2.488,8	1.170,5

Yıl	Ort. Tüketim (MWh)	Ort. Fiyat (TL/MWh)	Fiyat Std. Sapma
2023	37.023	2.157,0	713,0
2024	39.013	2.209,9	667,6
2025	40.241	2.603,4	809,4

2022'deki standart sapmanın 1.170,5 TL/MWh'a ulaşması yalnızca bir istatistik değil; modelleme kararı açısından da belirleyicidir. Hem ortalama hem varyans bu denli değişmişse, model 2021 verisinden öğrendiklerini güncel koşullara uygulamaya çalışırken yanıltıcı ön varsayımlar edinmiş olacaktır. Fiyat modellerini yalnızca 2022–2025 dönemine kısıtlama kararı bu gerekçeyle verilmiştir; sezgisel bir tercih değil, verinin doğrudan dayattığı bir sonuçtur.

4. YÖNTEM

Bu bölümde araştırmanın metodolojik çerçevesi açıklanmaktadır. Modelleme kararları sırasıyla veri bölme stratejisi, özellik mühendisliği, değerlendirme metrikleri ve model ailelerinin tanımı başlıkları altında ele alınmaktadır. Her karar, salt teknik gerekçeyle değil; kullanılan verinin yapısal özellikleri ve gerçek dünya uygulanabilirlik koşulları da gözetilerek alınmıştır.

4.1. Araştırma Tasarımı ve Veri Bölme Stratejisi

Zaman serisi problemlerinde rastgele örnekleme ile gerçekleştirilen eğitim-test bölmesi, gelecek bilgisinin modele sızmasına yol açar ve performans metriklerini gerçekçi olmayan biçimde iyimser kılar [17]. Bu nedenle çalışmada kronolojik sırayı koruyan zaman temelli bölme stratejisi benimsenmiştir.

Eğitim kümesi olarak 2021-2023 yılları, doğrulama kümesi olarak 2024 yılı ve test kümesi olarak 2025 yılı kullanılmıştır. Yaklaşık 26.280 gözlemden oluşan eğitim dönemi model parametrelerinin öğrenilmesi; 8.784 gözlemden oluşan doğrulama dönemi ise hiperparametre seçimi ile hibrit model ağırlıklarının belirlenmesi için ayrılmıştır. Test dönemi, nihai model değerlendirmesi için eğitim sürecinden tamamen yalıtılmış ve gerçek bir dış örneklem olarak tutulmuştur.

Tablo 4.1: Zaman temelli train-validation-test bölme stratejisi

Dönem	Yıllar	Gözlem Sayısı	Amaç
Eğitim (Train)	2021–2023	~26.280	Model parametrelerinin öğrenilmesi
Doğrulama (Validation)	2024	~8.784	Hiperparametre seçimi; hibrit ağırlık öğrenimi
Test	2025	~8.760	Nihai dış örneklem değerlendirmesi

Fiyat modellerinde 2021 yılı ayrıca dikkatle ele alınmıştır. Fiyat modelinin 2022 yılından itibaren eğitilmesi tercih edilmiştir; çünkü 2021 yılı fiyat seviyesi sonraki yıllara göre farklı bir rejim göstermekte ve bu durum modelin genel fiyat seviyesini yanlış öğrenmesine yol açabilmektedir. Makine öğrenmesi modellerinin karşılaştırılmasında TimeSeriesSplit yöntemi kullanılmış ve her katlamada eğitim seti zaman içinde geçmişten geleceğe doğru genişletilmiştir.

İlk denemelerde zaman sırası korunmadığında bazı modellerin hatası beklenenden fazla düşüyordu. Bu durum özellikle zaman serisi problemlerinde düşük hata değerinin tek başına güvenilir olmadığını, bölme stratejisinin en az model seçimi kadar önemli olduğunu gösterdi.

4.2. Özellik Mühendisliği

Ham saatlik seriler, elektrik talebindeki günlük ve haftalık düzenleri doğrudan modele aktarmak için yeterli değildir. Bu nedenle gecikmeli değişkenler, hareketli istatistikler, döngüsel takvim kodlamaları ve hava durumu türevleri oluşturulmuştur. Tüm türetilmiş değişkenlerde yalnızca geçmiş gözlemlere dayalı shift ve rolling işlemleri kullanılmıştır. Aşağıdaki alt başlıklar, her bir özellik grubunun hangi mantıkla seçildiğini açıklamaktadır.

4.2.1. Gecikmeli Değişkenler

Tüketim tahmini için 24, 48, 72 ve 168 saatlik gecikmeler kullanılmıştır. Bu seçim, elektrik tüketiminde bir önceki günün aynı saati ve bir önceki haftanın aynı saatinin güçlü referans noktaları olmasına dayanmaktadır. Fiyat tahmini için 24, 48, 168 ve 336 saatlik gecikmeler oluşturulmuştur. 336 saatlik gecikme iki haftalık tekrar etkisini yakalamak amacıyla eklenmiştir.

Günlük modellere geçildiğinde ise haftalık gecikmeler ve Fourier terimleri kullanılmıştır. Böylece saatlik modellerde ayrıntılı olarak temsil edilen kısa dönem örüntüler, günlük ölçekli modellerde daha sade fakat daha kararlı bir yapıya dönüştürülmüştür.

4.2.2. Hareketli İstatistikler

Yakın geçmişteki seviye ve oynaklığı modele taşımak için 24 saatlik ve 168 saatlik hareketli ortalama ile hareketli standart sapma değişkenleri hesaplanmıştır. Fiyat serisi için ayrıca 24 saatlik minimum-maksimum değerler, haftalık maksimum fiyat, 24 saatlik fiyat değişimi ve fiyat volatilitesi gibi değişkenler eklenmiştir. Bu değişkenler fiyatın yalnızca seviyesini değil, son dönemdeki dalgalanma yapısını da temsil etmektedir.

Hareketli istatistikler hesaplandıktan sonra bir adım geciktirilmiş, böylece tahmin anında bilinmeyen hedef değerinin aynı satıra sızması engellenmiştir.

4.2.3. Döngüsel Zaman Kodlaması

Saat, haftanın günü ve ay değişkenleri doğrudan 0-23 veya 1-12 gibi sayılarla kullanıldığında döngüsel yapı bozulmaktadır. Örneğin 23. saat ile 0. saat birbirine komşu olmasına rağmen sayısal olarak uzak görünür. Bu nedenle saat, gün ve ay değişkenleri sinüs-kosinüs çiftleriyle kodlanmıştır.

$$hour_sin = \sin(2\pi \cdot saat / 24), \quad hour_cos = \cos(2\pi \cdot saat / 24) \quad (4.1)$$

Aynı dönüşüm haftanın günü için 7, ay değişkeni için 12 periyotla uygulanmıştır. Bu yaklaşım hem doğrusal modellerin hem de ağaç tabanlı modellerin takvimsel döngüleri daha doğal şekilde öğrenmesine yardımcı olmuştur.

4.2.4. Hava Durumu Türevleri

Elektrik tüketimi ile sıcaklık arasındaki ilişki doğrusal değildir. Düşük sıcaklıklarda ısıtma, yüksek sıcaklıklarda ise soğutma ihtiyacı tüketimi artırır. Bu nedenle sıcaklık karesi, Heating Degree Day (HDD) proxy, Cooling Degree Day (CDD) proxy, çiy noktası proxy ve heat index değişkenleri oluşturulmuştur. Hava durumu değişkenlerinin 24 saatlik gecikmeleri de eklenmiş, böylece tahmin senaryosunda geçmiş hava koşullarının etkisi modele aktarılmıştır.

Çalışmada kullanılan hava değişkenleri Türkiye geneli için seçilen şehirlerin nüfus ağırlıklı ortalaması olarak oluşturulmuştur. İstanbul, Ankara, İzmir, Antalya, Gaziantep, Samsun ve Erzurum yapıya dahil edilmiştir. Böylece tek bir şehir yerine daha genel bir ulusal hava göstergesi elde edilmeye çalışılmıştır.

4.2.5. Veri Sızıntısı Kontrolü

Gerçek tahmin ortamında model, tahmin anındaki tüketim, üretim veya fiyat değerini bilemez. Bu nedenle tüketim modelinde anlık fiyat ve üretim değişkenleri, fiyat modelinde ise anlık tüketim, üretim ve fiyatın aynı satırdan türetilen spike/dip göstergeleri model girdisinden çıkarılmıştır. Fiyat modeli için net yük bilgisi de anlık haliyle değil, 24 saat gecikmeli olarak kullanılmıştır.

Bu karar özellikle önemlidir; çünkü enerji verilerinde aynı zaman damgasındaki değişkenler birbirine çok güçlü bağlıdır. Bu değişkenleri doğrudan modele vermek test hatasını yapay biçimde düşürebilir, fakat gerçek bir ileri tahmin senaryosunda aynı başarı elde edilemez.

Başta modele daha fazla değişken eklemenin her zaman daha iyi olacağını düşünmek kolay gelebilir; ancak bazı değişkenlerin aslında geleceği gösterdiğini fark etmek, model kurmanın sadece algoritma seçmekten ibaret olmadığını gösterdi.

4.3. Değerlendirme Metrikleri

Model başarısını tek bir ölçüt üzerinden değerlendirmek yanıltıcı olabilir. RMSE büyük hataları karesel olarak ağırlıklandırır ve özellikle fiyat sıçramaları gibi aykırı durumların kritik olduğu problemlerde temel ölçüt olarak benimsenmiştir:

$$RMSE = \sqrt{\frac{1}{n} \cdot \sum_i (y_i - \hat{y}_i)^2} \quad (4.2)$$

MAE ise ortalama mutlak hatayı ölçerek modelin tipik hata büyüklüğünü yorumlamaya olanak tanır ve aykırı gözlemlerden RMSE'ye kıyasla daha az etkilenir:

$$MAE = \frac{1}{n} \cdot \sum_i |y_i - \hat{y}_i| \quad (4.3)$$

Farklı ölçeklerdeki modelleri karşılaştırmak için MAPE ve sMAPE metrikleri kullanılmıştır. sMAPE, gerçek değerın sıfıra yakın olduğu durumlarda MAPE'nin aşırı büyümesini simetrik ölçeklendirme yoluyla dengelemektedir:

$$MAPE = 100/n \cdot \sum_i |y_i - \hat{y}_i| / |y_i| \quad (4.4)$$

$$sMAPE = 100/n \cdot \sum_i 2|y_i - \hat{y}_i| / (|y_i| + |\hat{y}_i|) \quad (4.5)$$

Elektrik fiyat serisinde gerçek değerın 10 TL/MWh'ın altında kaldığı gözlemler MAPE hesabından dışarıda bırakılmıştır; bu eşiğin altındaki satırlar bölüm paydasını kararsız kılarak hatayı şişirmektedir. Son olarak NRMSE, tahmin hatasını hedef değişkenin gözlem aralığına göre normalize eder ve farklı seriler arasındaki kaba bir karşılaştırma zemini sunar:

$$NRMSE (\%) = 100 \cdot RMSE / (y_{(max)} - y_{(min)}) \quad (4.6)$$

4.4. Modelleme Yaklaşımı ve Model Ailelerine Genel Bakış

Çalışmada tek bir model ailesine bağlı kalmak yerine doğrusal modeller, ağaç tabanlı modeller, boosting modelleri, klasik zaman serisi modelleri, derin öğrenme modelleri ve hibrit meta-öğrenme yaklaşımı birlikte değerlendirilmiştir. Bu seçim, modellerin aynı veri setinde farklı hata türleri üretip üretmediğini görmeyi ve mümkünse bu farklılıkları hibrit modelde avantaja çevirmeyi amaçlamaktadır.

Tablo 4.2: Kullanılan model ailelerine genel bakış

Model Ailesi	Modeller	Uygulama Düzeyi	Temel Amaç
Doğrusal modeller	Doğrusal Regresyon, RidgeCV	Saatlik tüketim ve fiyat	Otoregresif yapılı serilerde temel karşılaştırma
Ağaç tabanlı modeller	Karar Ağacı, Random Forest	Saatlik tüketim ve fiyat	Doğrusal olmayan ilişki ve değişken etkileşimleri

Model Ailesi	Modeller	Uygulama Düzeyi	Temel Amaç
Boosting modelleri	Gradient Boosting, XGBoost, LightGBM	Saatlik ve günlük	Karmaşık eşik ilişkilerini hata düzeltme yapısıyla öğrenmek
Klasik zaman serisi	SARIMAX, VARMAX	Günlük tüketim ve fiyat	Otoregresif ve mevsimsel yapıları açık biçimde modellemek
Derin öğrenme	CNN-LSTM, TFT	Saatlik ve günlük	Uzun/kısa dönem zamansal bağımlılıkları öğrenmek
Hibrit model	Ridge tabanlı stacking	Günlük nihai tahmin	Model ailelerini birleştirerek dış örneklem hatasını azaltmak

Çalışmada saatlik ve günlük olmak üzere iki farklı zaman çözünürlüğü benimsenmiştir. Makine öğrenmesi modelleri (Doğrusal Regresyon, Ridge, ElasticNet, Karar Ağacı, Random Forest, Gradient Boosting, XGBoost, LightGBM) ve derin öğrenme modelleri (CNN-LSTM, TFT) saatlik yapıda uygulanmıştır; bu seçim, kısa vadeli tahmin probleminin özüne uygun olup saatlik gelecek bilgileri (tatil, saat dilimi) ile gecikmeli özelliklerin doğrudan kullanılabilmesine olanak tanımaktadır. SARIMAX ve VARMAX modelleri ise günlük frekansta çalıştırılmıştır. Bu tercihin iki gerekçesi vardır: birincisi, SARIMAX’ın parametre tahmini ve grid araması saatlik 43.824 gözlem üzerinde hesaplama açısından zorlu olacak, mevsimsel parametre $s=24$ ile $s=168$ ikili döngüsellik tek yapıda yakalamak güçleşecektir; ikincisi, SARIMAX’ın açık mevsimsellik yapısı günlük ölçekte ($s=7$, haftalık döngü) daha kararlı ve yorumlanabilir sonuçlar üretmektedir. Hibrit meta-öğrenme modeli ise günlük frekanstaki temel model tahminlerini birleştirerek nihai değerlendirmeyi günlük ölçekte gerçekleştirmiştir. Bu mimari tercih, Tablo 4.2’deki “Uygulama Düzeyi” sütununda özetlenmiştir.

4.5. Makine Öğrenmesi Modelleri

4.5.1. Doğrusal Regresyon ve Ridge Regresyon

Doğrusal Regresyon, hedef değişkeni ile açıklayıcı değişkenler arasındaki ilişkiyi doğrusal bir fonksiyonla özetler:

$$y_t = \beta^0 + \beta^1 x_{1,t} + \beta^2 x_{2,t} + \dots + \beta_p x_{p,t} \quad (4.7)$$

Katsayılar hata kareler toplamını minimize edecek biçimde tahmin edilir. Model bu çalışmada iki role sahiptir: birincisi, daha karmaşık modellerin kendisini aşıp aşmadığını görmek için bir taban çizgisi işlevi görür; ikincisi, güçlü otoregresif yapının baskın olduğu fiyat serisinde beklenmedik biçimde rekabetçi sonuçlar üretilmediği gözlemlenir.

Çok sayıda gecikmeli değişken ve hareketli ortalama özelliği içeren veri setlerinde çoklu doğrusal bağlantı (multicollinearity) katsayı tahminlerini istikrarsız kılar. Ridge Regresyon bu sorunu L2 düzenleme cezasıyla çözer:

$$\min_{\beta} \sum_t (y_t - \hat{y}_t)^2 + \lambda \sum_j \beta_j^2 \quad (4.8)$$

λ arttıkça katsayılar küçülür ve aşırı uyum eğilimi azalır. RidgeCV ile en uygun λ değeri çapraz doğrulama yoluyla seçilmiştir. Aynı model hibrit yapının meta-öğrenicisi olarak da

kullanılmıştır; bu rol, farklı temel modellerden gelen tahminleri dengeli biçimde birleştirme kapasitesiyle doğrudan örtüşmektedir.

4.5.2. ElasticNet

ElasticNet, L1 ve L2 cezalarını tek bir amaç fonksiyonunda birleştirir:

$$\min_{\beta} \sum_t (y_t - \hat{y}_t)^2 + \lambda^1 \sum_j |\beta_j| + \lambda^2 \sum_j \beta_j^2 \quad (4.9)$$

L1 cezası bazı katsayıları tam sıfıra iterek değişken seçimi işlevi görürken, L2 cezası kalan katsayıların kararlılığını artırır. Özellik mühendisliği aşamasında türetilen çok sayıda değişkenin bir kısmının gereksiz olabileceği düşünüldüğünde ElasticNet, Ridge'e göre daha seyrek bir çözüm üretebilmesi açısından araştırılmaya değer bir alternatiftir.

Pratikte ElasticNet, Ridge'den belirgin bir kazanım sağlamadı. Bunun nedeni özellik setindeki yüksek korelasyonlu değişkenlerin L1 cezasının işini zorlaştırmasıdır; bu değişkenleri önceden sadeleştirmek, algoritmanın otomatik seyrekleştirmesini beklemenin önüne geçiyor. Yine de her iki modeli birlikte denemek, doğrusal ailenin bu veri setinde ne kadar ileri gidebileceğinin sınırını görmek açısından öğretici oldu.

4.6. Karar Ağacı Tabanlı Modeller

4.6.1. Karar Ağacı

Karar Ağacı, girdi uzayını ardışık ikili bölünmeler aracılığıyla alt bölgelere ayırır ve her bölgedeki gözlemlerin ortalamasını tahmin olarak kullanır:

$$\hat{y} = \sum_m c_m \cdot \mathbb{1}(x \in R_m) \quad (4.10)$$

Bölünmeler hata kareler toplamını azaltacak biçimde seçilir. Model, tek başına kullanıldığında aşırı uyum riskini kontrol etmek güçtür; bu çalışmada karar ağacı esas olarak Random Forest, XGBoost ve LightGBM'in temel yapı taşı olarak yer almakta ve tekil sonuçları üst sınır bir referans olarak sunulmaktadır.

4.6.2. Random Forest

Random Forest, her biri farklı bootstrap örnekleminden ve rastgele seçilmiş bir özellik alt kümesinden eğitilen B karar ağacının ortalamasını alır:

$$\hat{y}_{RF} = \frac{1}{B} \cdot \sum_{\beta} T_{\beta}(x) \quad (4.11)$$

Ağaçların bağımsız eğitilmesi ve ortalamanın alınması varyansı belirgin biçimde düşürür. Ancak bu ortalamanın yarattığı yumuşatma etkisi, ani tüketim piklerini veya fiyat sıçramalarını yakalamayı güçleştirebilir. Boosting modellerine kıyasla daha kararlı fakat daha az keskin tahminler üreten Random Forest, özellikle model çeşitliliğini artırmak açısından hibrit yapıya katkı sağlamaktadır.

Random Forest çalıştırıldığında RMSE değeri XGBoost'a kıyasla daha yüksek çıktı; ancak bunu bir başarısızlık olarak değil, modelin doğası olarak okumak gerekiyor. Aşırı uyum riski düşük, tahminler kararlı — bu özellikler sonunda hibrit yapıda denge unsuru işlevi gördü. Tek başına birinci olmak zorunda olmayabilir.

4.7. Gradient Boosting Tabanlı Modeller

4.7.1. Gradient Boosting

Gradient Boosting, her adımda bir önceki modelin kalıntısını hedef alarak zayıf öğrenicileri ardışık biçimde ekler:

$$F_m(x) = F_{m-1}(x) + \nu \cdot h_m(x) \quad (4.12)$$

Burada ν öğrenme oranını, h_m ise yeni eklenen zayıf öğreniciyi ifade eder. Eğitim, belirli bir kayıp fonksiyonunu minimize edecek yönde sürdürülür. Elektrik tüketimi ve fiyatı gibi değişkenler arası ilişkilerin karmaşık ve doğrusal olmadığı serilerde bu ardışık hata düzeltme yapısı önemli bir avantaj sağlar.

4.7.2. XGBoost

XGBoost, Gradient Boosting çerçevesini düzenleştirme ve ikinci dereceden Taylor açılımından yararlanan bir optimizasyon şemasıyla pekiştirmiştir. Amaç fonksiyonu şöyle gösterilebilir:

$$Obj = \sum_i L(y_i, \hat{y}_i) + \sum_k \Omega(f_k), \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_j w_j^2 \quad (4.13)$$

Yaprak sayısı T ve yaprak ağırlıkları w_j üzerindeki ceza, modelin karmaşıklığını doğrudan kontrol altına alır. XGBoost bu çalışmada tüketim tahmininde güçlü performans göstermiş; bunun arkasında sıcaklık, gecikmeli tüketim ve takvim değişkenleri arasındaki karmaşık etkileşimleri etkili biçimde öğrenmesinin yattığı değerlendirilmektedir.

4.7.3. LightGBM

LightGBM, XGBoost'un seviye odaklı ağaç büyütme stratejisinden farklı olarak kaybı en çok azaltan yaprağı öncelikli büyütür. Histogram tabanlı bölünme bu yapıyı büyük veri setlerinde hızlı ve bellek etkin kılar. Yaprak odaklı büyüme karmaşık ilişkileri daha hızlı öğrenebilmekle birlikte, hiperparametre seçimi dikkatli yapılmadığında derinlerin kontrol edilemez biçimde artmasına ve aşırı uyuma neden olabilir. Bu nedenle çalışmada maksimum yaprak sayısı ve minimum yaprak verisi gibi parametreler kontrollü aralıklarda aranmıştır.

LightGBM'in eğitim hızı, 43.000'den fazla satırı olan bu veri setinde XGBoost'a kıyasla oldukça belirgin biçimde hissedildi. Hiperparametre araması sırasında `num_leaves` değeri geniş tutulduğunda doğrulama hatasının belirli bir noktadan sonra artmaya başladığı görüldü; ağaç derinliğini kontrol etmenin ne kadar kritik olduğu bu şekilde anlaşıldı.

4.8. Klasik Zaman Serisi Modelleri

4.8.1. SARIMAX

SARIMAX, ARIMA yapısına mevsimsel bileşen ve dışsal değişken desteği ekler. Genel gösterimi şu şekildedir:

$$\Phi_{P(B^s)} \cdot \varphi_{P(B)} \cdot (1 - B)^d \cdot (1 - B^s)^D \cdot y_t = \theta_{Q(B^s)} \cdot \theta_{Q(B)} \cdot \varepsilon_t + \beta \cdot X_t \quad (4.14)$$

Saatlik tüketim ve fiyat serisinde günlük, haftalık ve mevsimsel döngüler SARIMAX'ı bu çalışmaya dahil etmek için yeterli gerekçe oluşturmaktadır. Modelin en belirgin kısıtı, doğrusal çerçevede çalışmasıdır; piyasanın ani kırılma noktalarını ve değişkenler arası eşik etkilerini öğrenmede makine öğrenmesi modellerinin gerisinde kalması bu yüzden beklenen bir sonuçtur.

4.8.2. VARMAX

VARMAX, birden fazla zaman serisini eş zamanlı modelleyerek seriler arası dinamik ilişkileri açık biçimde yakalama olanağı sunar:

$$y_t = c + A^1 y_t^{-1} + \dots + A_p y_t^{-p} + M^1 \varepsilon_t^{-1} + \dots + M_\varphi \varepsilon_t^{-\varphi} + B X_t + \varepsilon_t \quad (4.15)$$

Tüketim ve fiyat arasındaki etkileşimi birlikte ele alması teorik olarak güçlü bir özelliktir. Bununla birlikte çok değişkenli yapı parametre sayısını hızla artırır; yüksek oynaklığa sahip fiyat serisi varlığında bu durum genelleme başarısını sınırlayabilir. Sonuçlar değerlendirilirken bu hesaplama maliyeti ve model kararlılığı dengesi göz önünde bulundurulmuştur.

VARMAX'ın teorik çekiciliğine rağmen pratikte fiyat serisinin oynaklığı bu modelin üstesinden gelemeyeceği bir engel oluşturdu. Sonuçla incelendiğinde iki seri arasındaki eş zamanlı modellemenin burada avantajdan çok parametre yüküne dönüştüğü görüldü. Bu deneyim, teoride güçlü görünen bir modelin verinin yapısıyla uyuşmadığında beklenenden zayıf sonuç üretebileceğini somut olarak gösterdi.

4.9. Derin Öğrenme Modelleri

4.9.1. CNN-LSTM

CNN-LSTM, evrimsel sinir ağlarının yerel örüntü çıkarma kapasitesini LSTM'nin uzun dönemli bellek yapısıyla birleştirir. CNN katmanı, zaman penceresi üzerinde kısa dönemli bağımlılıkları öğrenirken LSTM katmanı daha uzak geçmişi bütünleşik hücre durumları aracılığıyla taşır. LSTM'nin temel hücre güncellemesi şöyle özetlenebilir:

$$c_t = f_t \odot c_t^{-1} + i_t \odot \tilde{c}_t \quad (4.16)$$

Bu mimarinin saatlik enerji verisine uygulanmasının gerekçesi, kısa dönemli salınımlar ile çok saatlik bağımlılıkları aynı ağ içinde temsil etme gereksinimidir. Özellik mühendisliği aşamasında zaten gecikmeli değerler ve hareketli ortalamaların oluşturulmuş olması da, derin öğrenme modellerinin ham seriden öğreneceği kısmı daraltır; bu nedenle CNN-LSTM'nin ağaç tabanlı modellere kıyasla daha sınırlı bir iyileştirme alanı bulması şaşırtıcı değildir.

CNN-LSTM'yi kurarken en çok zaman harcanan adım pencere boyutu ve katman sayısının belirlenmesiydi. Ama asıl fark edilen şu oldu: özellik mühendisliği aşamasında gecikme değişkenlerini zaten elle oluşturulduğu için modelin kendi başına öğreneceği zamansal yapı büyük ölçüde daralmıştı. Bir anlamda ağa öğrenmeden önce işin önemli bir kısmı belirtilmişti; bu da modelin bağımsız katkısını sınırladı.

4.9.2. Temporal Fusion Transformer (TFT)

TFT, çok değişkenli zaman serisi tahmini için tasarlanmış dikkat mekanizması tabanlı bir modeldir. Geçmiş gözlemler, bilinen gelecek değişkenler ve statik girdileri farklı işleme kanallarıyla ele alır. Dikkat mekanizması genel olarak şu biçimde ifade edilir:

$$Attention(Q, K, V) = softmax(QK^T / \sqrt{d_k}) \cdot V \quad (4.17)$$

TFT'nin bu çalışmaya dahil edilmesinin gerekçeleri: farklı zaman adımlarının tahmin üzerindeki önem paylarını dinamik olarak öğrenebilmesi ve değişken önem sıralaması üretmesi. Bu ikinci özellik, yalnızca doğruluk değil yorumlanabilirlik açısından da değer taşımaktadır. Öte yandan transformatör mimarisinin tam potansiyeline ulaşabilmesi için genellikle büyük veri hacimleri ve kapsamlı hiperparametre araması gerekmektedir; bu kısıtın sonuçlara yansımaları olası görülmektedir.

TFT'yi çalıştırmak projenin teknik olarak en zorlu adımıydı. PyTorch-Forecasting kütüphanesinin TimeSeriesDataSet gereksinimleri başta kafa karıştırıcı gelebiliyor; bir hata mesajının ardından kategorik değişkenlerin string'e dönüştürülmesi gerektiği anlaşıldı. GPU olmadan eğitim saatler sürdüğünden hiperparametre aramasını yeterince genişletilemedi. Sonuçların bu kısıtla yorumlanması gerekiyor, çünkü mimari daha elverişli bir donanımda farklı davranabilir.

4.10. Hibrit Meta-Öğrenme Modeli

Her model ailesinin güçlü olduğu bağlam farklıdır: SARIMAX mevsimsel düzenlilikleri iyi yakalarken, boosting modelleri eşik etkilerinde öne çıkar, derin öğrenme modelleri ise uzun dönemli zamansal bağımlılıkları temsil etmede avantaj sağlar. Bu gözlemden hareketle, temel modellerin birbirini tamamladığı durumlarda stacking tabanlı bir hibrit yapının toplam hatayı azaltacağı varsayımı oluşturulmuştur.

Hibrit yapıda temel modeller önce bağımsız olarak eğitilmiş ve doğrulama seti üzerinde tahmin üretmiştir. Bu tahminler, meta-öğrenicinin girdi özelliklerine dönüştürülmüştür:

$$\hat{y}_{hybrid} = \alpha^0 + \alpha^1 \hat{y}^1 + \alpha^2 \hat{y}^2 + \dots + \alpha_m \hat{y}^m \quad (4.18)$$

Meta-öğrenici olarak Ridge Regresyon seçilmiştir; aşırı uyum riskini L2 cezasıyla sınırlarken farklı model tahminlerini dengeli biçimde ağırlıklandırabilmesi bu tercihin temel gerekçesidir:

$$\min_{\alpha} \sum_t (y_t - \hat{y}_{hybrid,t})^2 + \lambda \sum_j \alpha_j^2 \quad (4.19)$$

Meta-öğrenici katsayıları doğrudan yüzdesel katkı olarak yorumlanamaz; bu katsayılar, modelin temel tahminleri hangi yön ve büyüklükte kullandığını gösteren ağırlıklardır. Test seti hibrit modelin eğitiminde hiçbir biçimde kullanılmamış ve nihai değerlendirme için korunmuştur.

5. BULGULAR

Bu bölümde 2025 yılı dış örneklem test dönemine ait model performansları aktarılmakta ve sonuçlar yalnızca hata metrikleri açısından değil, neden bu sonuçların elde edildiği açısından da değerlendirilmektedir. Bulgular iki tahmin problemi sonuçlarıdır: saatlik elektrik tüketimi ve saatlik elektrik fiyatı. Fiyat serisi, arz-talep dinamiklerine, yenilenebilir üretim dalgalanmalarına ve sistem kısıtlarına açık yapısıyla tüketim serisinden yapısal olarak farklıdır; bu nedenle iki problemin model sıralamaları kısmen ayrıışmaktadır. Değerlendirme çerçevesine ilişkin önemli bir not: Bölüm 4.3'te açıklandığı üzere, makine öğrenmesi (5.1–5.2) ve derin öğrenme (5.4) modelleri saatlik frekansta değerlendirilmiştir; SARIMAX/VARMAX modelleri ise günlük frekansta çalıştırılmıştır. Hibrit değerlendirme (5.5) günlük ölçekte gerçekleştirilmiştir. Bu nedenle Tablo 5.1–5.2 ile Tablo 5.3 arasındaki RMSE birimlerini doğrudan karşılaştırmak doğru değildir; bölüm başlıklarındaki ölçek bilgisi (saatlik / günlük) göz önünde bulundurularak okunmalıdır.


5.1. Makine Öğrenmesi Modelleri: Saatlik Tüketim

Tablo 5.1: Makine öğrenmesi saatlik tüketim modelleri karşılaştırması

Model	CV_RMSE (MWh)	CV_sMAPE (%)	Test_RMSE (MWh)	Test_MAPE (%)	Test_sMAPE (%)
XGBoost	1.202,87	1,982	1.016,68	1,73	1,74
Gradient Boosting	1.209,21	2,054	1.048,33	1,81	1,82
LightGBM	1.220,61	2,017	1.031,44	1,78	1,79
RidgeCV	1.281,40	2,511	1.142,15	2,18	2,19
Doğrusal Reg.	1.288,02	2,537	1.155,20	2,21	2,22
Random Forest	1.351,04	2,210	1.198,77	2,05	2,06
Karar Ağacı	1.797,96	3,140	1.689,44	3,08	3,11

Tüketim tahmininde XGBoost, 1.016,68 MWh RMSE ve %1,74 sMAPE ile en iyi test performansını göstermiştir. LightGBM ve Gradient Boosting bunu yakın değerlerle izlemekte; üç boosting modeli arasında belirgin bir fark yoktur. Öte yandan doğrusal modeller ile Random Forest'in bu üçlünün yaklaşık %10-15 gerisinde kalması dikkat çekicidir.

Bu tablonun en önemli çıkarımı, tüketimin doğrusal bir sürecin ötesine geçtiğini net biçimde göstermesidir. Özellikle sıcaklık ile tüketim arasında belirli eşik değerlerinin üstünde ve altında hızlanan ısıtma/soğutma talebi, boosting modellerinin karar ağacı yapısı aracılığıyla öğrenebildiği türden bir doğrusal olmayan ilişkidir. Doğrusal Regresyon ve Ridge bu eşik etkilerini yakalayamamaktadır. Random Forest ise kararlı ama ortalamacı tahminler üretir; bu yapı, ani tüketim piklerinin kısmen yumuşatılmasına yol açmaktadır.



Şekil 5.1: Tüketim SHAP Analizi

SHAP sonuçları lag_168 ve lag_24 değişkenlerinin tüketim modelinde en önemli girdiler arasında olduğunu göstermiştir. Bu durum, Türkiye elektrik tüketiminde aynı saatin bir hafta önceki ve bir gün önceki değerlerinin güçlü referanslar oluşturduğunu desteklemektedir. Hava durumu türevlerinin de etkili olması, tüketim tahmininde yalnızca geçmiş tüketim bilgisinin değil, sıcaklık kaynaklı talep değişiminin de belirleyici olduğunu göstermektedir.

Tüketim modeli sonuçlarında en dikkat çekici nokta, karmaşık modellerin açık ara farkla değil, küçük ama tutarlı farklarla öne çıkması. Bu, iyi hazırlanmış gecikmeli değişkenlerin bazen model mimarisinden daha belirleyici olabileceğini düşündürülebilir.

5.2. Makine Öğrenmesi Modelleri: Saatlik Fiyat


Tablo 5.2: Makine öğrenmesi saatlik fiyat modelleri karşılaştırması

Model	CV_RMSE (TL/MWh)	CV_sMAPE (%)	Test_RMSE (TL/MWh)	Test_sMAPE (%)	Test_NRMSE (%)
Doğrusal Reg.	377,85	14,17	351,93	14,99	10,08
RidgeCV	381,32	14,31	358,12	15,24	10,25

Model	CV_RMSE (TL/MWh)	CV_sMAPE (%)	Test_RMSE (TL/MWh)	Test_sMAPE (%)	Test_NRMSE (%)
LightGBM	457,13	15,99	412,47	17,33	11,81
Gradient Boosting	481,62	16,80	438,95	18,21	12,57
Random Forest	489,46	17,11	447,83	18,55	12,82
XGBoost	493,90	17,16	452,31	18,74	12,95
Karar Ağacı	572,11	20,09	531,77	21,44	15,23

Fiyat tahmininde sıralama tüketim tahminine kıyasla kayda değer biçimde farklılaşmaktadır: tüketimde sonuncu olan doğrusal modeller burada öne geçmekte, tüketimde birinci olan XGBoost ise sonlara düşmektedir. Bu tersine dönüşün açıklaması fiyat serisinin yapısında yatmaktadır. Elektrik fiyatları, tüketim dinamiklerinin ötesinde arz-talep dengesi, yenilenebilir üretim miktarı ve ani sistem kısıtları gibi faktörlerden etkilenmektedir; bu etkilerin büyük bölümü, geçmiş fiyat gözlemlerinde yoğunlaşan otoregresif bir sinyal olarak kendini göstermektedir. Güçlü otoregresif sinyal doğrusal modelleri beklenmedik ölçüde başarılı kılarken, modelin öğreneceği doğrusal olmayan kalıntı yapısı görece daha zayıftır.

Boosting modellerinin fiyat tahmininde doğrusal modellerin gerisinde kalmasının bir diğer nedeni, fiyat serisindeki ani sıçramaların tarihsel örüntülerden bağımsız davranmasıdır. Geçmiş örneklerde yer almayan bir piyasa koşulu yaşandığında, doğrusal olmayan ilişkileri öğrenmiş ağaç modelleri de bu koşulu tahmin etmekte güçlük çekmektedir.



Şekil 5.2: Fiyat SHAP Analizi

Fiyat modelindeki SHAP çıktılarında lag_fiyat_24, price_diff_24 ve rolling_fiyat_mean_24 değişkenlerinin öne çıkması, fiyat oluşumunda bir gün önceki fiyat seviyesinin ve kısa dönemli fiyat değişiminin merkezi rol oynadığını göstermektedir. Bu nedenle fiyat tahmininde daha karmaşık modelin her zaman daha iyi sonuç vermediği, serinin yapısına uygun basit modellerin de güçlü olabileceği görülmüştür.


Tüketimde başarılı olan XGBoost fiyat tarafında geriye düşerken, doğrusal modelin öne çıkması “en iyi model” kavramının hedef değişkene göre değiştiğini çok net gösteriyor.

5.3. Klasik Zaman Serisi Modelleri: SARIMAX ve VARMAX

Tablo 5.3: Günlük zaman serisi model karşılaştırması.

Model	Hedef	RMSE	MAPE (%)	sMAPE (%)	NRMSE (%)
SARIMAX	Günlük Tüketim (MWh/gün)	39.804,1	2,96	2,94	6,39
VARMAX	Günlük Tüketim (MWh/gün)	60.858,9	5,06	5,06	9,77
SARIMAX	Günlük Fiyat (TL/MWh)	375,2	11,91	11,43	15,81
VARMAX	Günlük Fiyat (TL/MWh)	415,7	13,13	13,11	17,51

SARIMAX, günlük tüketim tahminine %2,94 sMAPE ile oldukça iyi yaklaşmaktadır. Elektrik tüketiminde belirgin haftalık ve mevsimsel döngüler bulunduğu için, bu döngüleri açık parametre yapısıyla temsil eden SARIMAX önemli bir avantaj elde eder. Bununla birlikte, tüketim serisindeki doğrusal olmayan bileşen ve sıcaklık etkileşimleri modelin erişemediği alanda kalmakta; bu da en iyi boosting modellerine kıyasla daha yüksek hatanın temel kaynağını oluşturmaktadır.



Şekil 5.3: Zaman Serileri Model Sonuçları

Şekil 5.3, SARIMAX ve VARMAX modellerinin günlük tahminlerini gerçek değerlerle karşılaştırmaktadır. SARIMAX tüketim grafiği incelendiğinde modelin haftalık pik-dip döngülerini genel hatlarıyla yakaladığı, ancak bazı kış/yaz piklerinde hafif üst tahmin ürettiği görülmektedir; bu, doğrusal modellerin ısıtma/soğutma talebinin eşik etkilerini tüm genişliğiyle öğrenemediğinin somut yansımasıdır. SARIMAX fiyat grafiğinde ise model yavaş değişen fiyat bölgelerinde tatmin edici bir performans sergilemiş, buna karşın ani fiyat sıçramalarında gerçek değerlerin belirgin biçimde altında kalmıştır. Bu pattern, sabit parametrelili doğrusal modellerin yapısal bir sınırlılığını yansıtmaktadır: modelin öğrendiği düzey, rejim değişimi yaşanan sıçramaları tahmin etmek için yeterli değildir. VARMAX tahmin eğrilerinin fiyat tarafında daha yüksek sapmış görünmesi ise çok değişkenli yapının fiyat oynaklığına karşı daha kırılgan olduğunu göstermektedir.

VARMAX, tüketim-fiyat birlikteliğini aynı anda modelleme imkânı sunmasına rağmen her iki hedef için de SARIMAX'ın gerisinde kalmıştır. Bunun arkasında iki faktör yatmaktadır: fiyat serisinin yüksek oynaklığı, parametre sayısı katlanarak artan VARMAX'ın genelleme başarısını baskılamakta; öte yandan iki seri arasındaki eş anlamlı ilişkiyi yakalamak için yeterli varyasyonun var olup olmadığı da belirsizdir. Tüm bu sınırlılıklar, VARMAX'ın teorik olarak çekici olmakla birlikte pratikte daha öngörülebilir SARIMAX kadar etkili olamadığını göstermektedir.

5.4. Derin Öğrenme Modelleri: CNN-LSTM ve TFT

Tablo 5.4: Derin öğrenme saatlik model karşılaştırması

Model	Hedef	RMSE	MAE	sMAPE (%)	NRMSE (%)
CNN-LSTM	Saatlik Tüketim	1.970,4	1.420,3	3,57	5,17

Model	Hedef	RMSE	MAE	sMAPE (%)	NRMSE (%)
TFT	Saatlik Tüketim	1.612,9	1.164,1	2,85	4,23
CNN-LSTM	Saatlik Fiyat (TL/MWh)	812,2	557,8	25,79	23,26
TFT	Saatlik Fiyat (TL/MWh)	691,5	507,3	24,44	19,81

Saatlik derin öğrenme sonuçlarında TFT hem tüketim hem de fiyat hedefinde CNN-LSTM modelinden daha iyi performans göstermiştir. TFT tüketim için %2,85 sMAPE, fiyat için %24,44 sMAPE değerine ulaşmıştır. Bu durum attention mekanizmasının farklı zaman adımlarına değişken ağırlık verebilmesinin CNN-LSTM yapısına kıyasla avantaj sağladığını düşündürmektedir.

Buna rağmen derin öğrenme modelleri, saatlik makine öğrenmesi modellerinin özellikle fiyat tahminindeki seviyesine ulaşamamıştır. Bunun birkaç nedeni vardır. Birincisi, özellik mühendisliği aşamasında lag ve rolling değişkenleri zaten zaman bilgisinin önemli kısmını modele açıkça vermektedir. İkincisi, fiyat serisindeki ani sıçramalar derin öğrenme modellerinin de zorlandığı nadir ve düzensiz olaylardır. Üçüncüsü, eğitimler CPU üzerinden yürütülmüştür; bu durum daha geniş model ve hiperparametre araması yapılmasını sınırlamış olabilir.

Dolayısıyla bu çalışmada derin öğrenme modelleri başarısız olarak değil, daha fazla veri, donanım ve ayar araması gerektiren modeller olarak değerlendirilmiştir. TFT'nin tahmin aralığı üretmesi ve değişken önemlerini yorumlama olanağı sunması, doğruluk dışında da faydalı bilgiler sağlamaktadır.

5.5. Hibrit Meta-Öğrenme Modeli

Tablo 5.5, temel modellerin hibrit çerçevesiyle entegre edilmiş hâllerini ve nihai hibrit model sonuçlarını karşılaştırmaktadır. Tablodaki SARIMAX RMSE değerlerinin Tablo 5.3'tekilerden farklı olduğu dikkat çekebilir; bu fark, iki tablonun farklı yapılandırmaları yansıtmasından kaynaklanmaktadır. Modellerin mutlak performansı için Tablo 5.3 ve 5.4 referans alınmalı; Tablo 5.5 yalnızca hibrit çerçeve içi karşılaştırma amacıyla okunmalıdır.

Tablo 5.5: Nihai günlük hibrit model karşılaştırması (test dönemi 2025)

Model	RMSE	MAE	sMAPE (%)	NRMSE
SARIMAX — Tüketim (MWh/gün)	59.117,9	37.714,8	4,14	0,0949
LightGBM — Tüketim	50.884,5	39.322,7	4,10	0,0817
XGBoost — Tüketim	49.196,0	37.672,3	3,92	0,0790
CNN-LSTM — Tüketim	74.548,4	59.382,5	6,29	0,1197

Model	RMSE	MAE	sMAPE (%)	NRMSE
TFT — Tüketim	90.553,6	71.658,4	7,76	0,1454
HİBRİT — Tüketim	36.180,0	25.932,5	2,76	0,0581
— — —	—	—	—	—
SARIMAX — Fiyat (TL/MWh)	341,3	250,4	10,38	0,1438
LightGBM — Fiyat	335,3	249,3	10,31	0,1413
XGBoost — Fiyat	365,6	273,4	11,09	0,1540
CNN-LSTM — Fiyat	507,2	442,1	18,12	0,2136
TFT — Fiyat	533,6	452,8	18,35	0,2248
HİBRİT — Fiyat	315,1	238,6	9,90	0,1327

Günlük nihai değerlendirmede hibrit model tüketim tahmininde açık biçimde en iyi sonucu üretmiştir. En iyi tekil model olan XGBoost %3,92 sMAPE değerine sahipken, hibrit model bu değeri %2,76'ya düşürmüştür. Bu iyileşme, temel modellerin aynı hatayı tekrar etmek yerine farklı dönemlerde farklı güçlü yönler göstermesinden kaynaklanmaktadır. SARIMAX mevsimsel ve haftalık düzenleri, XGBoost ve LightGBM doğrusal olmayan ilişkileri, CNN-LSTM ise zamansal pencerelerden gelen ek sinyali modele taşımıştır.

Ridge meta-öğrencinin TFT modelini hem tüketim hem de fiyat hedefinde budadığı görülmektedir. Bu sonuç, TFT'nin saatlik tabloda CNN-LSTM'den iyi olmasına rağmen günlük hibrit yapıda diğer modellerden yeterince farklı bir katkı sunmadığını göstermektedir. Dolayısıyla hibrit modelin başarısı bütün modelleri eşit şekilde kullanmasından değil, doğrulama döneminde gerçekten ek bilgi sağlayan modelleri öne çıkarmasından gelmektedir.

Fiyat tahmininde hibrit model yine en iyi sonucu vermiş, ancak iyileştirme tüketimdeki kadar büyük olmamıştır. LightGBM %10,31 sMAPE ile en iyi tekil modelken, hibrit model %9,90 sMAPE'ye ulaşmıştır. Bu sınırlı iyileşme fiyat serisinin ani sıçramalarındaki ortak hata yapısıyla açıklanabilir. Eğer temel modeller aynı fiyat şoklarını birlikte kaçırıyorsa, meta-öğrenici bu ortak kör noktayı tamamen gideremez.

Sonuç olarak hibrit meta-öğrenme yaklaşımı, tek bir modelin sınırlılıklarını aşmak için etkili bir çerçeve sunmuştur. Düzenlileştirmeli bir meta-öğrencinin temel modellerin doğrulama kümesi tahminlerinden beslenmesi, hem aşırı uyum riskini kontrol altında tutmuş hem de modeller arası tamamlayıcılıktan gerçek bir kazanım sağlanmasına olanak tanımıştır.

Tablo 5.3, bağımsız olarak eğitilen SARIMAX modelinin doğrudan günlük zaman serisi üzerindeki sonuçlarını göstermektedir. Tablo 5.5'te ise SARIMAX hibrit stacking çerçevesi içinde yeniden yapılandırılmış; tüm temel modellerin tahminleri aynı günlük pipeline üzerinden geçirilmiş ve Ridge meta-öğrencisinin girdisine dönüştürülmüştür. Tahmin formatı ve değerlendirme penceresi (doğrulama kümesi üzerinden ağırlık öğrenimi) bu iki yapıda farklılaşmaktadır.

6. SONUÇ

Bu çalışmada Türkiye elektrik piyasası için kısa vadeli elektrik tüketimi ve fiyat tahmini problemi ele alınmıştır. Çalışmanın çıkış noktası, elektrik tüketimi ile piyasa fiyatının aynı sistem içinde yer almasına rağmen farklı dinamiklere sahip olmasıdır. Tüketim tarafında günlük, haftalık ve mevsimsel düzenler belirgin biçimde gözlemlenirken, fiyat tarafında piyasa koşulları, yapısal kırılmalar ve ani sıçramalar tahmin sürecini daha karmaşık hâle getirmiştir.

Bu amaçla 2021–2025 dönemine ait saatlik elektrik üretim, tüketim ve fiyat verileri; Türkiye'nin farklı iklimlerini temsil eden yedi şehre ait meteorolojik verilerle birleştirilmiştir. Veri seti oluşturulurken eksik değer kontrolleri yapılmış, zaman uyumu sağlanmış, fiyat serisindeki sınırlı sayıda eksik gözlem interpolasyon yöntemiyle tamamlanmış ve modele uygun bir veri yapısı elde edilmiştir. Ayrıca saat, haftanın günü, ay, hafta sonu ve resmî tatil bilgileri gibi takvim değişkenleri ile gecikmeli değişkenler modele dahil edilmiştir.

Elde edilen sonuçlar, elektrik tüketimi tahmininin fiyat tahminine kıyasla daha başarılı biçimde modellenemediğini göstermiştir. Bunun temel nedeni, tüketim serisinin güçlü otokorelasyon yapısına ve düzenli takvim etkilerine sahip olmasıdır. Özellikle bir önceki günün aynı saati ve bir önceki haftanın aynı saati gibi gecikmeli değişkenler, tüketim tahmininde belirleyici olmuştur. Meteorolojik değişkenler de tüketim tahmini açısından anlamlı bir destek sağlamış; ancak bu katkının tek başına değil, takvim ve gecikmeli tüketim değişkenleriyle birlikte değerlendirildiğinde daha anlamlı olduğu görülmüştür.

Fiyat tahmini tarafında ise daha farklı bir tablo ortaya çıkmıştır. 2022 yılında fiyat serisinde görülen belirgin yapısal kırılma, modellerin genel performansını doğrudan etkilemiştir. Bu kırılma nedeniyle 2021 yılı fiyat verisinin sonraki dönemleri temsil etme gücü zayıflamış ve fiyat modellerinde eğitim dönemi buna göre yeniden değerlendirilmiştir. Fiyat serisindeki ani yükselişler, dip değerler ve yüksek oynaklık, yalnızca geçmiş fiyat, tüketim veya meteorolojik değişkenlerle tam olarak açıklanamamıştır. Bu durum, elektrik fiyatının yalnızca fiziksel talep koşullarından değil, aynı zamanda piyasa yapısı, kaynak dağılımı, yakıt maliyetleri ve düzenleyici koşullar gibi dışsal faktörlerden de etkilendiğini göstermektedir.

Çalışmada farklı model aileleri aynı veri seti üzerinde karşılaştırılmıştır. Makine öğrenmesi modelleri, özellikle tüketim tahmininde güçlü sonuçlar üretmiştir. Zaman serisi modelleri serinin genel yapısını anlamak açısından yararlı olmuş; ancak çoklu mevsimsellik, doğrusal olmayan ilişkiler ve yapısal kırılmalar karşısında sınırlı kalmıştır. Derin öğrenme modelleri ise bazı durumlarda başarılı sonuçlar vermesine rağmen, her zaman daha basit modellere üstünlük sağlayamamıştır. Bu bulgu, model karmaşıklığının tek başına başarı garantisi olmadığını göstermesi açısından önemlidir.

Genel olarak en dengeli sonuçlar hibrit yaklaşım ile elde edilmiştir. Farklı modellerin tahminlerini bir araya getiren bu yapı, tekil modellerin zayıf kaldığı dönemlerde daha kararlı sonuçlar üretmiştir. Bu nedenle çalışmanın temel bulgularından biri, enerji tahmini problemlerinde tek bir model ailesine bağlı kalmak yerine, farklı modellerin güçlü yönlerini birleştiren yaklaşımların daha güvenilir olabileceğidir.

Sonuç olarak bu çalışma, Türkiye için kısa vadeli elektrik tüketimi ve fiyat tahmini problemini aynı veri altyapısı üzerinde ele almış; meteorolojik değişkenlerin, takvim etkilerinin ve gecikmeli özelliklerin tahmin performansı üzerindeki rolünü incelemiştir. Tüketim tahmininde yüksek düzenlilik ve güçlü geçmiş bağımlılığı nedeniyle daha başarılı sonuçlar elde edilirken, fiyat tahmininde yapısal kırılmalar ve piyasa oynaklığı belirleyici sınırlayıcı unsurlar olmuştur. Bu yönüyle çalışma hem enerji talep tahmini hem de piyasa fiyat tahmini için uygulanabilir bir modelleme çerçevesi sunmaktadır.

7. ÇALIŞMANIN SINIRLILIKLARI

Bu çalışmada kapsamlı bir veri seti ve farklı modelleme yaklaşımları kullanılmış olsa da elde edilen sonuçların bazı sınırlılıklar çerçevesinde değerlendirilmesi gerekir. Bu sınırlılıkların açık biçimde belirtilmesi hem çalışmanın kapsamını doğru tanımlamak hem de sonuçların hangi koşullarda geçerli olduğunu göstermek açısından önemlidir.

İlk sınırlılık, meteorolojik verilerin temsil biçimiyle ilgilidir. Çalışmada ülke genelindeki hava koşullarını yaklaşık olarak temsil etmeyi amaçlayan ve farklı iklim bölgelerini kapsayan yedi şehir kullanılmıştır. Ancak Türkiye'nin coğrafi ve iklimsel çeşitliliği oldukça yüksektir. Yalnızca yedi şehir üzerinden hesaplanan ağırlıklı meteorolojik değişkenler, tüm ülkenin gerçek hava etkisini birebir yansıtmayabilir. Özellikle bölgesel tüketim yoğunlukları, sanayi bölgeleri ve yerel iklim farklılıkları daha ayrıntılı bir şekilde ele alınabilir.

İkinci sınırlılık, şehir ağırlıklarının belirlenmesiyle ilgilidir. Şehirlerin meteorolojik etkileri nüfus temelli bir yaklaşımla ağırlıklandırılmıştır. Nüfus, elektrik tüketimi için makul bir gösterge olsa da tek başına yeterli değildir. Sanayi yoğunluğu, ticari faaliyetler, bölgesel üretim yapısı ve hane halkı tüketim alışkanlıkları da elektrik talebini etkiler. Bu nedenle gelecekte tüketim bölgesi bazlı veya dağıtım şirketi bölgesi bazlı ağırlıkların kullanılması daha gerçekçi sonuçlar verebilir.

Üçüncü sınırlılık, fiyat tahmini için kullanılan değişken setidir. Elektrik fiyatları yalnızca tüketim, üretim ve hava koşullarıyla belirlenmez. Doğal gaz fiyatları, döviz kuru, kömür maliyetleri, hidroelektrik üretim kapasitesi, baraj doluluk oranları, yenilenebilir enerji üretim tahminleri, ithalat-ihracat durumu ve piyasa katılımcılarının teklif stratejileri fiyat oluşumunda önemli rol oynar. Bu çalışmada bu değişkenlerin tamamına ulaşamadığı için fiyat tahmin modelleri sınırlı bir bilgi setiyle kurulmuştur. Bu durum, özellikle ani fiyat sıçramalarının tahmin edilmesini zorlaştırmıştır.

Dördüncü sınırlılık, 2022 yılında fiyat serisinde gözlenen yapısal kırılmadır. Bu kırılma, serinin istatistiksel yapısını önemli ölçüde değiştirmiştir. Bu nedenle geçmiş dönem verilerinin sonraki dönemleri temsil etme gücü azalmıştır. Modelleme sürecinde bu durum dikkate alınmış olsa da yapısal kırılmaların tamamen ortadan kaldırılması mümkün değildir. Özellikle fiyat tahmininde elde edilen hataların önemli bir bölümü bu piyasa rejimi değişikliğiyle ilişkilidir.

Beşinci sınırlılık, derin öğrenme modellerinin donanım ve eğitim süresi kısıtları altında değerlendirilmiş olmasıdır. CNN-LSTM ve Temporal Fusion Transformer gibi modeller, daha geniş hiperparametre aramaları ve daha uzun eğitim süreçleriyle farklı sonuçlar verebilir. Ancak bu çalışma kapsamında kullanılan donanım ve zaman kısıtı yüzünden kurulan model mimarileri ayrıntılı biçimde denenememiştir. Bu nedenle derin öğrenme sonuçları, kullanılan mimari ve eğitim ayarları bağlamında değerlendirilmelidir.

Altıncı sınırlılık, nihai değerlendirme döneminin belirli bir test aralığına dayanmasıdır. Zaman serisi problemlerinde model performansı seçilen test dönemine duyarlı olabilir. Bu çalışmada kronolojik ayırım korunmuş ve veri sızıntısından kaçınılmıştır; ancak farklı yıllar üzerinde tekrarlanan rolling-origin veya genişletilmiş pencere doğrulama yaklaşımları model performansının kararlılığını daha güçlü biçimde test edebilir.

Son olarak, bu çalışma tahmin performansına odaklanmıştır. Modellerin pratik enerji planlaması süreçlerine entegrasyonu, karar destek sistemlerinde kullanımı veya ekonomik maliyet etkisi ayrıca analiz edilmemiştir. Oysa tahmin hatalarının gerçek sistem maliyetine nasıl yansıdığı, enerji sektörü açısından en az hata metrikleri kadar önemli bir konudur.

8. GELECEĞE YÖNELİK ÇALIŞMALAR

Elde edilen bulgular gelecekte geliştirilebilecek birçok araştırma yönüne işaret etmektedir.

İlk olarak, meteorolojik değişkenlerin etkisi daha detaylı biçimde incelenebilir. Çalışmada yedi şehir üzerinden bir hava göstergesi oluşturulmuştur. Gelecekte daha fazla şehir, bölgesel tüketim ağırlıkları veya dağıtım bölgesi bazlı hava verileri kullanılarak daha hassas bir temsil elde edilebilir. Ayrıca yalnızca anlık hava değişkenleri değil, gecikmeli sıcaklık gibi türetilmiş değişkenler de modele eklenebilir. Bu tür değişkenler, özellikle binaların ısıl ataleti nedeniyle tüketim tahmininde daha açıklayıcı olabilir.

İkinci olarak, fiyat tahmini için daha zengin dışsal değişkenler kullanılabilir. Doğal gaz fiyatı, döviz kuru, kömür fiyatı, hidroelektrik üretim kapasitesi, baraj doluluk oranları, rüzgâr ve güneş üretim tahminleri, ithalat-ihracat miktarları ve piyasa teklif verileri fiyat tahmin modellerine dahil edilebilir. Bu değişkenlerin eklenmesi, özellikle ani fiyat sıçramalarının ve piyasa rejimi değişimlerinin daha iyi anlaşılmasına katkı sağlayabilir.

Üçüncü olarak, yapısal kırılmaları dikkate alan özel modelleme yaklaşımları denenebilir. Fiyat serisinde 2022 yılında gözlenen kırılma, klasik modelleme yaklaşımlarının sınırlı kalabileceğini göstermiştir. Gelecek çalışmalarda rejim değişimli modeller, rolling window tahmin sistemleri, çevrimiçi öğrenme yaklaşımları veya kırılma sonrası döneme özel yeniden eğitilen modeller kullanılabilir. Bu sayede piyasa koşulları değiştiğinde modelin eski yapıya bağlı kalması önlenir.

Dördüncü olarak, hibrit modelleme yaklaşımı daha dinamik hâle getirilebilir. Bu çalışmada farklı modellerin çıktıları bir araya getirilerek daha kararlı sonuçlar elde edilmiştir. Gelecekte model ağırlıkları sabit tutulmak yerine döneme, mevsime, saat dilimine veya piyasa koşullarına göre değiştirilebilir. Örneğin bazı modeller gece saatlerinde daha başarılı olurken, bazıları puant saatlerde daha iyi performans gösterebilir. Dinamik ağırlıklandırma bu farklılıkları daha iyi değerlendirebilir.

Beşinci olarak, hata analizi daha ayrıntılı biçimde genişletilebilir. Modellerin yalnızca genel MAE, RMSE veya sMAPE değerleriyle değil; saat bazında, hafta içi/hafta sonu ayrımında, mevsimlere göre ve fiyat sıçraması dönemlerinde ayrı ayrı değerlendirilmesi faydalı olacaktır. Bu tür bir analiz, modelin hangi koşullarda güvenilir olduğunu ve hangi koşullarda dikkatli kullanılması gerektiğini daha açık biçimde gösterebilir.

Altıncı olarak, derin öğrenme modelleri daha kapsamlı biçimde denenebilir. Temporal Fusion Transformer, LSTM, GRU ve attention tabanlı farklı mimariler daha geniş hiperparametre aramalarıyla yeniden değerlendirilebilir. GPU destekli eğitim ortamlarında daha uzun pencere yapıları, farklı öğrenme oranları ve farklı mimari derinlikleri denenebilir. Bununla birlikte, bu tür modellerin yalnızca daha karmaşık oldukları için tercih edilmemesi; basit ve yorumlanabilir modellerle adil biçimde karşılaştırılması önemlidir.

Yedinci olarak, tahmin performansı istatistiksel anlamlılık testleriyle desteklenebilir. Örneğin Diebold-Mariano testi kullanılarak iki model arasındaki hata farkının rastlantısal olup olmadığı değerlendirilebilir. Bu yaklaşım, özellikle birbirine yakın performans gösteren modellerin karşılaştırılmasında daha sağlam bir yorum zemini sağlayacaktır.

Son olarak, geliştirilen tahmin çerçevesi operasyonel bir karar destek sistemine dönüştürülebilir. Saatlik tüketim ve fiyat tahminlerinin görselleştirildiği, model hatalarının izlendiği ve belirli eşik değerleri aşıldığında uyarı üreten bir sistem, çalışmanın pratik değerini artırabilir. Böyle bir yapı, enerji planlaması, talep yönetimi ve piyasa analizi gibi alanlarda doğrudan kullanılabilir.

Genel olarak gelecek çalışmalar, bu tezde kurulan temel veri ve modelleme altyapısını daha zengin dışsal değişkenler, daha ayrıntılı hata analizleri ve daha dinamik modelleme stratejileriyle geliştirebilir. Bu doğrultuda çalışma hem akademik araştırmalar hem de enerji sektörü uygulamaları için genişletilebilir bir başlangıç noktası sunmaktadır.

KAYNAKÇA

- [1] Box, G. E. P., Jenkins, G. M., Reinsel, G. C. ve Ljung, G. M. (2015). Time Series Analysis: Forecasting and Control (5. Baskı). Wiley.
- [2] Elamin, N. ve Fukushige, M. (2018). Modeling and forecasting hourly electricity demand by SARIMAX with interactions. *Energy*, 165, 257–268.
- [3] Taylor, J. W. ve McSharry, P. E. (2007). Short-term load forecasting methods: An evaluation based on European data. *IEEE Transactions on Power Systems*, 22(4), 2213–2219.
- [4] Weron, R. (2014). Electricity price forecasting: A review of the state-of-the-art with a look into the future. *International Journal of Forecasting*, 30(4), 1030–1081.
- [5] Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
- [6] Chen, T. ve Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, 785–794.
- [7] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. ve Liu, T. Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 3146–3154.
- [8] Madrid, E. A., Noguez, J., Neri, L. ve Robledo-Rella, V. (2021). Short-term electricity load forecasting with machine learning. *Information*, 12(2), 50.
- [9] Lundberg, S. M. ve Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 30.
- [10] Hochreiter, S. ve Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
- [11] Kong, W., Dong, Z. Y., Jia, Y., Hill, D. J., Xu, Y. ve Zhang, Y. (2019). Short-term residential load forecasting based on LSTM recurrent neural network. *IEEE Transactions on Smart Grid*, 10(1), 841–851.
- [12] Marino, D. L., Amarasinghe, K. ve Manic, M. (2016). Building energy load forecasting using deep neural networks. *IECON 2016 — 42nd Annual Conference of the IEEE Industrial Electronics Society*, 7046–7051.
- [13] Lim, B., Arik, S. O., Loeff, N. ve Pfister, T. (2021). Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4), 1748–1764.
- [14] Lago, J., De Ridder, F. ve De Schutter, B. (2018). Forecasting spot electricity prices: Deep learning approaches and empirical comparison of traditional algorithms. *Applied Energy*, 221, 386–405.
- [15] Makridakis, S., Spiliotis, E. ve Assimakopoulos, V. (2020). The M4 Competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74.
- [16] Smyl, S. (2020). A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting. *International Journal of Forecasting*, 36(1), 75–85.
- [17] Bontempi, G., Taieb, S. B. ve Le Borgne, Y. A. (2013). Machine learning strategies for time series forecasting. *Business Intelligence: Second European Summer School (eBISS 2012)*, Springer, 62–77.
- [18] Ghofrani, M., Ghayekhloo, M., Arabali, A. ve Ghayekhloo, A. (2015). A hybrid short-term load forecasting with a new input selection framework. *Energy*, 81, 777–786.
- [19] Fan, S., Chen, L. ve Lee, W. J. (2009). Machine learning based switching model for electricity load forecasting. *Energy Conversion and Management*, 50(6), 1371–1376.
- [20] EPIAŞ. (2026). Şeffaflık Platformu Elektrik Piyasası Veri Yayınları. <https://seffalik.epias.com.tr> (Erişim tarihi: 15 Mart 2026).
- [21] Open-Meteo. (2026). Historical Weather API Documentation. <https://open-meteo.com/en/docs/historical-weather-api> (Erişim tarihi: 15 Mart 2026).

ÖZGEÇMİŞ

İsim ve Soy İsim:

Kerem Reyhani

Doğum Tarihi:

18.09.2003

Doğum Yeri:

Hatay

Lise:

İstiklal Makzume Anadolu Lisesi (2017- 2021)

Deneyim:

Param (01.07.2024 – 29.07.2024)

Koç Medikal (21.07.2025 – 15.08.2025)